Evaluación de riesgos en el procesamiento automatizado de Documentos Nacionales de Identidad

José Carlos Sancho Núñez
Universidad de Extremadura
Centro Universitario de Mérida
Mérida, España
ORCID: 0000-0002-4584-6945
jcsanchon@unex.es

Antonio Calvo Picón
Universidad de Extremadura
Centro Universitario de Mérida
Mérida, España
ORCID: 0009-0008-1815-7686
acalvopic@unex.es

Sergio Guijarro Domínguez
Universidad de Extremadura
Escuela Politécnica de Cáceres
Cáceres, España
ORCID: 0009-0002-9436-8561
sergiosgd@unex.es

Víctor González Morales
Universidad de Extremadura
Escuela Politécnica de Cáceres
Cáceres, España
ORCID: 0009-0009-7504-9929
victorgomo@unex.es

***Resumen*—En este trabajo se propone un marco de evaluación de riesgos para el procesamiento automatizado de documentos de identidad a partir de imágenes capturadas por el propio usuario. El sistema considerado recibe fotografías del anverso y reverso del documento nacional de identidad (DNI), aplica un modelo de detección para localizar y recortar el documento, realiza reconocimiento óptico de caracteres (OCR) y ejecuta un conjunto de validaciones sobre los datos personales extraídos y sobre los elementos de seguridad visibles en el documento. A partir de las tasas de error observadas en cada etapa del *pipeline*, se definen escenarios de riesgo y se cuantifican probabilidades e impactos asociados a la aceptación de documentos falsos, al rechazo de documentos legítimos y a errores sistemáticos del sistema. El resultado es un marco que permite analizar, comparar y diseñar sistemas de verificación de documentos de identidad desde una perspectiva explícita de gestión de riesgos.**

***Index Terms*—Documentos de Identidad, evaluación de riesgos, verificación de identidad, OCR, fraude documental**

I. Introducción

El uso de fotografías de Documentos Nacionales de Identidad (DNI) tomadas con el teléfono móvil se ha generalizado en procesos de verificación remota de identidad, sobre todo en entornos financieros, administrativos y de servicios en línea. Esta tendencia ha impulsado el despliegue de sistemas automáticos que reciben imágenes del anverso y reverso del DNI, detectan y recortan el documento, aplican OCR y ejecutan validaciones sobre los datos extraídos.

Sin embargo, la dependencia de este *pipeline* automatizado introduce riesgos específicos: aceptación de documentos falsos o manipulados, rechazo de documentos legítimos y decisiones basadas en información parcial o errónea.

El objetivo de este trabajo es definir y aplicar un marco de evaluación de riesgos centrado en la cadena de procesamiento formada por captura de imágenes, detección y recorte del documento, OCR y validación de datos personales y elementos de seguridad del DNI. Por tanto, las contribuciones principales del artículo son las siguientes:

- Se define un marco de evaluación de riesgos específico para sistemas de verificación automática de documentos de identidad basados en captura de imágenes, detección, OCR y validación.
- Se describe una arquitectura de referencia para el procesamiento de DNI (anverso y reverso) que integra detección, OCR y validaciones sobre datos personales y elementos de seguridad.
- Se propone una metodología para derivar métricas de riesgo, como las tasas de aceptación de fraude y rechazo de documentos legítimos, a partir de las tasas de error técnicas observadas en cada etapa del sistema.

II. Marco teórico y trabajos relacionados

Los documentos oficiales (como DNI o pasaporte) son ampliamente utilizados para la verificación remota de identidad, especialmente en procesos KYC (*Know Your Customer*). Sin embargo, desde el punto de vista técnico los métodos tradicionales basados en el envío de copias escaneadas presentan riesgos de manipulación, falta de automatización y vulnerabilidades en la validación humana [1].

Por este motivo, son numerosos los trabajos que aplican técnicas de visión por computador para detectar, segmentar y recortar automáticamente documentos en imágenes capturadas desde dispositivos móviles [2]. Es en la etapa de extracción de datos, donde los modelos OCR como Tesseract o soluciones comerciales adaptadas permiten estructurar los campos textuales, aunque presentan limitaciones ante fondos complejos o baja calidad de imagen [**?**].

Por otro lado, la detección de documentos falsificados se apoya en el análisis visual de elementos de seguridad (hologramas, relieves, microtextos) y patrones de diseño característicos. En este sentido, algunos enfoques combinan redes neuronales convolucionales (CNN) con aprendizaje supervisado para distinguir documentos genuinos de alteraciones mediante anomalías gráficas o inconsistencias entre campos [3].

Aunque existen diversos marcos normativos y metodológicos para la gestión de riesgos en procesos de identificación, como [4], [5] o [6], la literatura específica sobre documentos de identidad físicos es limitada, lo que refuerza la relevancia de esta propuesta como herramienta práctica para caracterizar riesgos en entornos reales.

En base a lo referenciado, esta contribución identifica la necesidad de realizar evaluaciones de riesgo en verificación de identidad, asignando un nivel de confianza al proceso en función de parámetros técnicos (calidad de imagen, congruencia de campos, metadatos). Nuestra propuesta sigue la línea de modelos recientes que plantean marcos adaptativos, ajustando la validación según el tipo de documento, el canal de adquisición y la exposición al fraude [7].

III. Modelos de sistema y de amenazas

El sistema propuesto recibe las imágenes del anverso y reverso del DNI previamente capturadas digitalmente por el usuario. Sobre cada imagen se aplica un modelo de detección para localizar y recortar el documento, obteniendo una región de interés estable. A continuación, se ejecuta un proceso de OCR que extrae los campos de texto relevantes y aplica reglas de validación sobre los datos personales y sobre los elementos de seguridad visibles en el documento.

La presentación de documentos completamente falsificados, documentos legítimos alterados parcial o totalmente y usos indebidos de documentos legítimos en contextos para los que no estaban destinados son las principales amenazas y, por tanto, el análisis se estructura en torno a dos dimensiones: la confidencialidad de los datos de identidad tratados y la integridad de las decisiones de verificación. Se emplean métricas tales como la tasa de aceptación de fraude (FAR), la tasa de rechazo de documentos legítimos (FRR) y las tasas de error críticas en la extracción y validación de campos.

IV. Arquitectura técnica: captura, detección, OCR y validaciones

IV-A. Conjunto de datos

Para el entrenamiento y validación del modelo de detección y segmentación, se contruye un conjunto de datos propio compuesto por fotografías de DNI españoles. Todas las imágenes se obtienen con consentimiento explícito de los titulares y se procesan conforme a la normativa vigente (RGPD), garantizando su uso exclusivo para fines de investigación y anonimización de datos sensibles. Este enfoque asegura que el modele se entrene con imágenes que reflejan fielmente las condiciones de uso del sistema en un entorno real.

El dataset consta de un total de 73 imágenes, distribuidas de manera aproximadamente equitativa entre el anverso (41 imágenes) y el reverso (32 imágenes) del documento. Es importante destacar que, para el alcance de esta fase del proyecto, todas las imágenes corresponden a documentos genuinos, ya que el objetivo principal es la robustez en la detección geométrica del documento y no la clasificación de su autenticidad.

Una característica fundamental del conjunto de datos es su alta variabilidad, diseñada deliberadamente para simular un amplio espectro de escenarios de uso real. El conjunto incluye tanto imágenes de alta calidad, con buen enfoque, iluminación adecuada y perspectiva frontal, como un subconjunto de casos de desafío para entrenar la robustez del modelo. Estas últimas imágenes incorporan, de forma individual o combinada, errores comunes como desenfoque de movimiento (motion blur), rotaciones pronunciadas, distorsión de perspectiva y condiciones de iluminación deficientes.

El conjunto de datos se divide en dos subconjuntos siguiendo una proporción estándar: 60 imágenes (aproximadamente el 82 %) se destinan para el **entrenamiento** del modelo, y las 13 imágenes restantes (el 18 %) se utilizan para su **validación**. Finalmente, cada imagen en el conjunto de datos se anota manualmente, lo que genera máscaras de segmentación precisas que delinean el contorno exacto del DNI. Estas máscaras constituyen la verdad terreno (*ground truth*) que el modelo YOLO utiliza para aprender a localizar el documento.

IV-B. Captura de imágenes

La etapa de captura de imágenes es un pilar fundamental del sistema, ya que la calidad de la entrada impacta directamente en el rendimiento de los módulos de detección y OCR. Para mitigar los errores derivados de una captura deficiente, se definen requisitos técnicos clave: una resolución adecuada (e.g., Full HD) para asegurar la legibilidad de todos los campos; una iluminación uniforme que evite reflejos y sombras; un encuadre completo donde el documento sea totalmente visible; y un enfoque nítido para prevenir el desenfoque de movimiento (*motion blur*). Para facilitar al usuario el cumplimiento de estos requisitos, se diseña un flujo de interacción guiado. La interfaz muestra una silueta del documento para facilitar el encuadre y solicita de forma secuencial la captura del anverso y, posteriormente, la del reverso. Este proceso maximiza la calidad de la imagen de entrada, lo que reduce significativamente la probabilidad de errores en las etapas posteriores.

IV-C. Detección y recorte del documento

El primer paso del pipeline de procesamiento consiste en localizar de forma precisa el DNI dentro de la imagen de entrada. El objetivo de esta etapa es aislar el documento del fondo, independientemente de su posición, escala o de la distorsión de perspectiva, para normalizar la entrada de las fases posteriores.

Para esta tarea, se emplea un modelo de la familia YOLO (You Only Look Once), concretamente la versión `yolov8n-seg.pt` [8]. La elección de YOLOv8 se fundamenta en su arquitectura de última generación (*state-of-the-art*), que ofrece un excelente equilibrio entre velocidad y precisión. Se opta por la variante 'n' (nano) por ser un modelo extremadamente ligero, rápido y óptimo.

La decisión de utilizar un modelo de segmentación de instancias (`-seg`) en lugar de uno de detección de objetos convencional es un requisito crítico para el sistema. Un detector estándar únicamente proporciona una caja delimitadora rectangular (*bounding box*), siendo insuficiente para procesar documentos capturados en ángulo. En cambio, el modelo de segmentación genera una máscara poligonal que se ajusta con alta fidelidad al contorno exacto del DNI. Esta máscara permite la extracción fiable de las coordenadas de las cuatro esquinas del documento, incluso bajo una fuerte distorsión de perspectiva. Estos cuatro puntos son la entrada imprescindible para la etapa de recorte, donde se aplica una transformación de perspectiva para rectificar la imagen.

Proceso de Entrenamiento: El modelo se entrena siguiendo una estrategia de transferencia de conocimiento (*transfer learning*) [9]. Se parte de los pesos del modelo `yolov8n-seg.pt` pre-entrenado sobre el extenso dataset COCO [10], y se realiza un ajuste fino (*fine-tuning*) utilizando el conjunto de datos de DNI descrito en la sección anterior. Este enfoque permite aprovechar el conocimiento general de características visuales aprendido previamente, lo que acelera la convergencia y mejora el rendimiento final.

El entrenamiento se lleva a cabo en una estación de trabajo equipada con una GPU NVIDIA GeForce RTX 4070 de 12 GB (PyTorch 2.7.1, CUDA 11.8). Los principales hiperparámetros incluyen un tamaño de imagen (imgsz) de

640x640 píxeles para un buen compromiso entre detalle y eficiencia, un tamaño de lote (batch) de 16 para optimizar el uso de la VRAM, y un total de 60 épocas (epochs) para asegurar el correcto ajuste de los pesos.

Para mejorar la generalización del modelo y su robustez ante la variabilidad de las imágenes de entrada, se utilizan las técnicas de aumento de datos (*data augmentation*) que incorpora por defecto el framework de Ultralytics. Estas incluyen transformaciones geométricas (rotaciones, escalado, traslaciones) y fotométricas (cambios de brillo, contraste y saturación). Adicionalmente, se implementa un mecanismo de parada temprana (*early stopping*) con una paciencia de 50 épocas. Este mecanismo monitoriza el rendimiento del modelo en el conjunto de validación y detiene el entrenamiento si no se observa una mejora, evitando así el sobreajuste (*overfitting*).

Corrección de Perspectiva y Recorte: Una vez obtenida la máscara de segmentación del DNI, se aplica un algoritmo de procesamiento geométrico para generar un recorte rectificado del documento. El proceso, implementado con la librería OpenCV, sigue los siguientes pasos:

1. **Extracción del Contorno:** A partir de la máscara binaria generada por el modelo, se extraen los contornos mediante el algoritmo de Suzuki [11]. Se selecciona el contorno de mayor área para asegurar que se procese el objeto principal detectado, descartando posibles artefactos o detecciones erróneas de menor tamaño.
2. **Aproximación de los Vértices:** El contorno extraído se aproxima a un polígono utilizando el algoritmo de Ramer-Douglas-Peucker [12] (`cv2.approxPolyDP`). El objetivo es encontrar los cuatro vértices que definen las esquinas del documento. Se implementa un mecanismo de contingencia: si el algoritmo no logra identificar un cuadrilátero, el sistema recurre a un recorte rectangular simple basado en el *bounding box* del contorno.
3. **Ordenamiento de Puntos:** Los cuatro vértices identificados se ordenan en una secuencia canónica y predecible: superior-izquierda, superior-derecha, inferior-derecha e inferior-izquierda. Este paso es indispensable para calcular correctamente la matriz de transformación.
4. **Cálculo y Aplicación de la Homografía:** Se calcula la matriz de transformación de perspectiva (homografía) de 3x3 que mapea los cuatro vértices del DNI en la imagen original a las esquinas de una nueva imagen de destino rectangular y plana. Finalmente, se aplica esta transformación a la imagen original mediante la función `cv2.warpPerspective` [13], lo que da como resultado una imagen del DNI con vista frontal, libre de distorsión y fondo.

El resultado de esta etapa es una imagen normalizada de alta calidad que sirve de entrada para el módulo de OCR, lo que maximiza la probabilidad de una extracción exitosa del texto.

IV-D. OCR y extracción de campos

Tras el recorte del documento en la fase de detección, se aplica un proceso de OCR sobre las regiones correspondientes a los campos del DNI, tanto en el anverso como en el reverso. Para ello se emplea la biblioteca `tesseract.js`, una adaptación de Tesseract OCR para su ejecución en el navegador, que permite mantener todo el procesamiento en el lado cliente sin exponer datos personales a servidores externos.

El procedimiento parte de un conjunto de coordenadas normalizadas (expresadas en proporciones relativas a la imagen) que definen la posición de cada campo en ambas caras del documento. Estas posiciones han sido previamente definidas manualmente a partir del diseño del DNI 4.0, incluyendo variaciones para algunos elementos (como el número de soporte o el número de DNI, que pueden aparecer en múltiples ubicaciones). A partir de estas coordenadas, se extraen las regiones correspondientes mediante canvas HTML5, sobre las que se ejecuta el reconocimiento con Tesseract de forma individual por campo. Esta estrategia permite mejorar la precisión respecto a un OCR global, reduciendo ruido entre campos adyacentes.

La Tabla I muestra un ejemplo de los campos extraídos a partir de un DNI sintético (Figura 1). Esta representación no contiene datos reales y cumple con la legislación vigente de protección de datos personales. Los campos extraídos incluyen, entre otros: nombre, apellidos, número de DNI, fecha de nacimiento, fecha de emisión y caducidad, número de soporte, nacionalidad, sexo y el código CAN en el anverso, así como la dirección, municipio, progenitores, provincia, equipo expedidor y la zona de lectura mecánica (MRZ) en el reverso.

(a) Anverso del DNI sintético. (b) Reverso del DNI sintético.

Figura 1: Ejemplo completo de DNI sintético utilizado para validar el sistema de extracción OCR. Las imágenes no representan ningún documento real de identidad.

Tabla I: Ejemplo de campos extraídos a partir de un DNI sintético (Fig. 1).

Campo	Valor extraído
Campos del anverso (Fig. 1a)	
Nombre	CARMEN
Apellidos	ESPAÑOLA ESPAÑOLA
DNI	99999999R
Sexo	F
Nacionalidad	ESP
Fecha de nacimiento	01/01/1980
Fecha de expedición	02/06/2021
Fecha de caducidad	02/06/2031
Número de soporte	CAA000000
Código CAN	020631
Firma	(detectada pero no extraída)
Campos del reverso (Fig. 1b)	
Domicilio	AVDA DE MADRID S-N, MADRID
Municipio	MADRID
Provincia	MADRID
Equipo expedidor	0000
Progenitores	JUAN / CARMEN
MRZ	IDESPCAA0000004... (truncado)

El resultado de esta etapa es un objeto estructurado con los campos extraídos, que será posteriormente sometido a validaciones de formato, coherencia y consistencia inter-cara.

IV-E. Validación de datos personales

Tras la extracción OCR, los campos son normalizados y validados mediante reglas de formato específicas y comprobaciones cruzadas entre anverso y reverso. La validación abarca aspectos estructurales, semánticos y de coherencia interna.

Normalización y estructura: Se aplican expresiones regulares y reglas heurísticas para corregir errores típicos de OCR (`O` → `0`, `B` → `8`, etc.). Campos como el DNI (`99999999R`) o el número de soporte se ajustan a sus patrones esperados y se validan mediante cálculos de control como el módulo 23 (DNI) o el checksum MRZ (soporte). La Tabla II muestra ejemplos de correcciones aplicadas.

Tabla II: Correcciones aplicadas durante la normalización del número de soporte.

Sección	OCR Erróneo	Corrección
Prefijo	Dígitos	Reemplazados por letras `[A-Z]`
Sufijo	`O,D,N,Q,B,S,I`	`0,0,0,0,8,5,1`
Otros	Símbolos	Eliminados

Validación de fechas y consistencia: Las fechas de nacimiento, expedición y caducidad se aceptan con distintos formatos y se validan por coherencia lógica: edad plausible (1–115 años), no fechas futuras, caducidad vigente. El sistema verifica que el DNI y el soporte coincidan en anverso y reverso, y que los checksums de la MRZ sean correctos.

Resumen de reglas por campo: La Tabla III resume los patrones de validación aplicados a cada campo. Los valores que no superan la validación se marcan como `null`. La firma no es evaluada.

Tabla III: Resumen de patrones de validación por campo.

Campo	Regla o patrón
DNI	`[0-9]{8}[A-Z]` + control
Nombre / Apellidos	Mayúsculas sin símbolos, 2 bloques
Sexo	`[MF]`
Nacionalidad	ISO 3166 (`ESP`)
Fechas	`DD/MM/AAAA`, coherencia temporal
N.º Soporte	`[A-Z0-9]{9}` + checksum MRZ
CAN	`[0-9]{6}`
Equipo	`[0-9]{4}`
MRZ	3 líneas × 30, checksums y consistencia
Firma	– (no evaluada)

IV-F. Validación de elementos de seguridad

Además del contenido textual, el sistema contempla una validación preliminar de ciertos elementos estructurales y visuales del documento, con especial atención a la zona MRZ, sin realizar aún análisis profundo de patrones gráficos.

Zonas y criterios observados: Se consideran indirectamente algunas zonas características del documento:

- **Zona MRZ:** Validación de formato estructural (3 líneas, 30 caracteres).
- **Disposición general:** Comprobación de orientación, márgenes y alineación básica.
- **Relación geométrica de campos:** Se verifica consistencia visual con plantillas oficiales.

Validaciones aplicadas: El sistema aplica las siguientes comprobaciones:

- **Estructura y checksums MRZ:** Se verifica la codificación válida de caracteres y el correcto cálculo de dígitos de control en campos clave.
- **Homografía básica:** Se compara la geometría del documento con una plantilla canónica para detectar recortes anómalos o rotaciones, mejorando también la entrada para el OCR, siguiendo enfoques similares a los descritos en [14].

Limitaciones: Aún no se emplean modelos específicos para detección de elementos gráficos de seguridad (e.g., hologramas o tintas especiales), debido a:

- Variabilidad en la calidad de imagen (desenfoque, brillo, etc.).
- Restricciones del modelo empleado para la detección actual.
- Carencia de datasets para el entrenamiento especializado.

V. Metodología de evaluación de riesgos

La agrupación en tres escenarios se deriva del análisis de fallos observados durante el entrenamiento y validaión del sistema en cada fase del flujo de trabajo. A partir de las cinco fases principales (captura, detección y recorte, OCR y validación de datos del documento), se identifican errores recurrentes y se clasifican según impacto operativo y su relevancia con la integridad del proceso.

- **Aceptación de un documento falsificado (falso positivo):** Se produce cuando un documento manipulado supera todas las verificaciones. Suele deberse a fallos en la lectura de la MRZ, errores en checksums (e.g., número de soporte) o detecciones incorrectas que permiten procesar imágenes incompletas.
- **Rechazo de un documento legítimo (falso negativo):** Ocurre cuando un documento auténtico es descartado por errores de lectura o normalización. Las principales causas son OCR impreciso en campos críticos (fechas, DNI), artefactos que impiden validar la MRZ o normalizaciones que generan valores `null`.
- **Errores sistemáticos de extracción o validación:** Aparecen bajo condiciones de captura adversas (glare, sombras, baja resolución), en campos con tildes o estructuras particulares, o en validaciones específicas como el número de soporte. Estos fallos repetidos comprometen la fiabilidad operativa del sistema.

V-0a. Caracterización por fase: Cada escenario se relaciona con riesgos específicos en las cinco fases:

- **Captura:** Riesgo de imágenes con baja calidad, glare o rotación que afectan la detección.
- **Detección y recorte:** Riesgo de recortes incompletos o detecciones erróneas que permiten procesar documentos falsos.
- **OCR:** Riesgo de errores sistemáticos en caracteres críticos (confusión 0/O, 8/B) que impactan en las validaciones.
- **Validación de datos personales:** Riesgo de rechazo de documentos legítimos por normalizaciones incorrectas.
- **Validación de elementos de seguridad:** Riesgo de aceptar documentos falsificados si fallan las comprobaciones de MRZ o checksums.

Estos escenarios recogen las amenazas reales observadas durante el desarrollo y representan los tipos de fallo que el sistema puede producir en función de las tasas de detección fallida, OCR erróneo y validaciones incorrectas.

V-A. *Estimación de probabilidad e impacto*

La probabilidad de cada escenario se calcula a partir de las tasas de error obtenidas en cada módulo:

- E_d: fallos en detección y recorte (documento no detectado o parcialmente recortado).
- E_o: errores de OCR y normalización (fechas inválidas, confusiones `0/O`, `8/B`, campos `null`).
- E_v: fallos en validación (checksum MRZ, DNI inconsistente, número de soporte no válido).

El impacto se clasifica cualitativamente según las consecuencias operativas:

- **Bajo (B):** Errores puntuales y recuperables.
- **Moderado (M):** Reprocesos o afectación a decisiones de negocio.
- **Crítico (C):** Permite fraude o bloquea usuarios legítimos.

V-B. *Índice global de riesgo*

La probabilidad del escenario s se estima:

$$P_s = w_d \cdot E_d + w_o \cdot E_o + w_v \cdot E_v \tag{1}$$

donde los pesos w_d, w_o, w_v reflejan la relevancia relativa de cada módulo y cumplen:

$$w_d + w_o + w_v = 1.$$

Clasificamos el valor resultante como:

- $P_s > 0{,}66 \rightarrow A$ (Alta)
- $0{,}33 < P_s \leq 0{,}66 \rightarrow M$ (Media)
- $P_s \leq 0{,}33 \rightarrow B$ (Baja)

Obtenemos el índice final combinando probabilidad e impacto mediante la matriz de la Tabla IV.

Tabla IV: Matriz de evaluación de riesgos: combinación de probabilidad e impacto.

Impacto \ Probabilidad	**Alta**	**Media**	**Baja**
Crítico	Alto	Medio	Medio
Moderado	Medio	Medio	Bajo
Bajo	Medio	Bajo	Bajo

VI. Resultados y discusión

VI-A. *Evaluación del modelo de detección y recorte*

La evaluación del modelo de segmentación `yolov8n-seg.pt` se realiza con el objetivo de medir su capacidad para localizar con precisión el DNI y generar un recorte normalizado que sirva como entrada de alta calidad para el módulo OCR. Se analizan tanto métricas cuantitativas como resultados cualitativos.

VI-A1. Métricas del modelo: El rendimiento del modelo se evalúa sobre el conjunto de validación de 13 imágenes, que incluye tanto capturas de alta calidad como casos de desafío (imágenes con alta distorsión de perspectiva, rotación y desenfoque). Los resultados obtenidos para la tarea de segmentación se resumen en la Tabla V.

Tabla V: Métricas de rendimiento del modelo YOLOv8n-seg en el conjunto de validación.

Métrica	**Valor**
Precisión (Precision)	1.000
Exhaustividad (Recall)	0.998
mAP50	0.995
mAP50-95	0.933

A continuación, se interpretan las métricas obtenidas:

- **Precisión (Precision):** Mide la fiabilidad de las detecciones. Un valor de **1.000** indica que todas las instancias clasificadas como DNI corresponden efectivamente a documentos reales, lo que implica una ausencia total de falsos positivos.
- **Exhaustividad (Recall):** Evalúa la capacidad del modelo para encontrar todos los DNIs existentes en las imágenes. Un valor de **0.998** evidencia que el sistema es capaz de detectar casi la totalidad de los documentos presentes en el conjunto de validación.
- **mAP50:** Es la métrica principal para esta tarea, ya que evalúa la calidad de la máscara de segmentación. Considera una detección como correcta si el solapamiento (IoU) entre la máscara predicha y la real es de al menos el 50 %. El resultado de **0.995** demuestra una capacidad sobresaliente del modelo para generar máscaras que se ajustan con gran fidelidad a la forma del documento.
- **mAP50-95:** Es una métrica más estricta que promedia el mAP en múltiples umbrales de IoU (de 0.5 a 0.95). El alto valor de **0.933** confirma que las máscaras generadas son correctas y precisas en su contorno, incluso bajo los criterios de evaluación más exigentes.

En conjunto, estos valores refuerzan la conclusión de que el modelo es extremadamente fiable tanto para evitar falsas detecciones como para generar una base geométrica precisa para las etapas posteriores de procesamiento.

Para complementar estos datos cuantitativos, se presenta un resultado cualitativo en la Figura 2. La imagen muestra la salida del modelo YOLOv8n-seg sobre una captura de entrada, donde se puede observar la caja delimitadora (*bounding box*), la puntuación de confianza (0.93) y, de forma superpuesta, la máscara de segmentación poligonal que se adhiere con precisión al contorno del documento. Esta máscara es el resultado fundamental de esta etapa, ya que proporciona las coordenadas exactas de las esquinas del DNI, que son la entrada necesaria para el subsiguiente algoritmo de corrección de perspectiva. Una vez rectificada la imagen, esta se pasa al módulo de OCR para la extracción de texto.

Figura 2: Salida del modelo de detección y segmentación YOLOv8n-seg. Se muestra la caja delimitadora, la confianza de la detección (0.93) y la máscara de segmentación (en rojo) sobre la imagen original.

VI-B. Evaluación del módulo OCR y validación

El sistema OCR se basa en `tesseract.js 5.1.0` con modelo `spa.traineddata`. La evaluación del rendimiento se lleva a cabo mediante un conjunto de imágenes sintéticas anotadas, usando validaciones por campo con expresiones regulares.

Los resultados muestran alta precisión en campos estructurados como DNI, fechas, nacionalidad, número de soporte o código CAN. Por el contrario, presentan mayor tasa de error campos sensibles al contexto o al diseño gráfico del fondo, como nombre, apellidos o sexo. Las principales fuentes de error son:

- **Ruido visual**: Zonas gráficas con escudos, líneas o fondos coloridos afectan la segmentación del texto.
- **Coordenadas fijas**: El uso de recortes estáticos reduce la robustez ante variaciones en tamaño o alineación.

Precisión OCR estimada por campo: La Tabla VI resume la precisión cualitativa observada por campo en el entorno de pruebas.

Tabla VI: Tasa estimada de acierto del OCR por campo (documentos sintéticos).

Campo	Precisión estimada
DNI, MRZ	$> 98\,\%$
Fechas (nac., exp., cad.)	95–98 %
Nacionalidad, CAN, soporte	$> 95\,\%$
Nombre simple, apellidos claros	85–90 %
Nombre/apellidos compuestos	65–80 %
Sexo, domicilio, municipio	80–90 %
Equipo expedidor, progenitores	$> 90\,\%$
Firma	No evaluada

VI-C. Discusión

Los resultados obtenidos confirman la solidez del *pipeline* para el procesamiento automatizado del DNI. El módulo de detección y recorte presenta un rendimiento sobresaliente (**mAP50 de 0.995**), generando máscaras precisas incluso en imágenes con distorsión o baja calidad. Esta fiabilidad es clave para el OCR, ya que la corrección de perspectiva y la normalización geométrica minimizan los errores derivados de recortes estáticos.

Respecto al OCR, los campos estructurados y con patrones regulares (DNI, fechas, MRZ, número de soporte) alcanzan tasas de acierto superiores al 95 %. En contraste, los campos más sensibles al contexto —como nombres y apellidos compuestos— muestran mayor variabilidad debido a la complejidad visual del fondo y a diferencias tipográficas. En conjunto, los resultados evidencian un rendimiento muy alto en la extracción de información crítica y dejan identificados los principales retos en el tratamiento de texto libre.

VII. Conclusiones y trabajos futuros

En este artículo se ha presentado un marco de evaluación de riesgos para sistemas de verificación automática de documentos de identidad basados en captura de imágenes, detección, OCR y validaciones. La propuesta permite vincular las tasas de error técnicas del sistema con indicadores de riesgo tales como la aceptación de fraude y el rechazo de documentos legítimos, facilitando el diseño y la comparación de soluciones alternativas.

Como líneas de trabajo futuras, se plantea: (1) la mejora de los modelos base, mediante la ampliación del conjunto de datos de detección con imágenes reales y sintéticas, la evaluación de arquitecturas YOLO alternativas y el entrenamiento específico del modelo OCR sobre documentos de identidad; (2) la obtención dinámica de coordenadas para cada campo mediante detección automática de regiones de interés, eliminando la dependencia de posiciones fijas; (3) la incorporación de validaciones de elementos de seguridad visuales, como la detección de hologramas; y (4) la extensión del sistema para que sea capaz de procesar otros tipos de documentos de identidad, como pasaportes o permisos de conducir.

Agradecimientos

Esta iniciativa se realiza en el marco de los fondos del Plan de Recuperación, Transformación y Resiliencia, financiados por la Unión Europea (Next Generation) - Instituto Nacional de Ciberseguridad (INCIBE) en el Proyecto C108/23 “Detección de Falsificación de Documentos de Identidad mediante Técnicas de Visión por Computador e Inteligencia Artificial”.

Referencias

[1] R. Patel, A. Sharma, and M. Khan, “Digital identity verification: Transforming kyc with ai and emerging technologies,” *International Research Journal of Modernization in Engineering, Technology and Science*, vol. 5, no. 9, pp. 3104–3112, 2023. [Online]. Available: https://www.irjmets.com/uploadedfiles/paper/issue_9_september_2023/44476/final/fin_irjmets1693845854.pdf

[2] D. Karatzas *et al.*, “Real-time document detection and rectification for mobile platforms,” in *Proc. Int. Workshop on Human-Document Interaction*, 2016, descripción en Karatzas et al., Human-Document Interaction Systems. [Online]. Available: https://refbase.cvc.uab.es/files/KPR2016.pdf

[3] T. Aljuaid, M. Alawairdhi, and R. Alotaibi, “Id card spoofing detection using frequency features and cnns,” *Ingénierie des Systèmes d’Information*, vol. 30, no. 8, pp. 1–15, 2025. [Online]. Available: https://www.iieta.org/journals/isi/paper/10.18280/isi.300813

[4] *ISO/IEC 29100:2024 – Information technology — Security techniques — Privacy framework*, ISO/IEC Std., 2024, https://www.iso.org/standard/85938.html.

[5] *ISO/IEC 27005:2022 – Information security, cybersecurity and privacy protection — Guidance on managing information security risks*, ISO/IEC Std., 2022, https://www.iso.org/standard/80585.html.

[6] NIST SP 800-37 Revision 2, “Risk management framework (rmf) for information systems & organizations,” National Institute of Standards and Technology (NIST), Tech. Rep., 2019, https://doi.org/10.6028/NIST.SP.800-37r2.

[7] L. S. Dasu, M. Dhamija, G. Dishitha, A. Vivekanandan, and V. Sarasvathi, “Defending against identity threats using risk-based authentication,” *Cybernetics and Information Technologies*, vol. 23, no. 2, pp. 105–123, 2023. [Online]. Available: https://doi.org/10.2478/cait-2023-0016

[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023, versión 8.0.0, Licencia AGPL-3.0.

[9] C. Tan, F. Sun, T. Kong, W. Zhang, C. Yang, and C. Liu, “A survey on deep transfer learning,” in *Proc. Int. Conf. Artif. Neural Netw. (ICANN)*, 2018, pp. 270–279.

[10] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2014, pp. 740–755.

[11] S. Suzuki and K. Abe, “Topological structural analysis of binary images by border following,” *Comput. Vis. Graph. Image Process.*, vol. 30, no. 1, pp. 32–46, 1985.

[12] D. H. Douglas and T. K. Peucker, “Algorithms for the reduction of the number of points required to represent a digitized line or its caricature,” *Cartographica*, vol. 10, no. 2, pp. 112–122, 1973.

[13] G. Bradski, *The Opencv Library*, 11 2000, vol. 25.

[14] Z. Li, J. Zhang, S. Gu, L. Van Gool, and R. Timofte, “Document rectification and illumination correction using a patch-based cnn,” in *Proc. ACM Int. Conf. Multimedia*, 2019, pp. 1643–1651. [Online]. Available: https://dl.acm.org/doi/10.1145/3355089.3356563