Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos

Fernando Broncano Morgado[1], Marcos Jesús Sequera Fernández[1], Óscar Mogollón Gutiérrez[1], Mohammadhossein Homaei[1 2], and Pablo García Rodríguez[1]

[1] Grupo de Ingeniería de Medios, Universidad de Extremadura, Extremadura, Spain
{fbroncano, marcosjesus, oscarmg}@unex.es, mhomaein@alumnos.unex.es, pablogr@unex.es

[2] Research and Development Dept., Ambling, Edificio Tajo, 10004 Cáceres, Spain
mhomaei@ambling.es

Resumen La generación de datos sintéticos poblacionales emerge como solución para estudios que requieren gran volumen de información personal, evitando riesgos de privacidad, como en la generación sintética de documentos nacionales de identidad. Este trabajo propone tres metodologías para crear una población sintética española, integrando datos del Instituto Nacional de Estadística (INE) sobre nombres, apellidos, distribución geográfica, ingresos y estructura de hogares. La primera aproximación emplea selección aleatoria simple, la segunda utiliza distribuciones ponderadas por frecuencias poblacionales, mientras la tercera incorpora distribuciones estadísticas y relaciones entre hogares. Los datos se almacenaron en Neo4j, permitiendo análisis de redes entre individuos, municipios y hogares. La validación, realizada sobre 100.000 personas, demostró que la tercera experiencia replica con mayor precisión la distribución real de edad, género, ingresos y tamaño de hogares, ajustándose a la estadística nacional española. Los resultados destacan la capacidad de estos datos sintéticos para simular fenómenos como movimientos migratorios, dinámicas epidemiológicas o estudios socioeconómicos, con un coste computacional aceptable sobre cualquier equipo. Este enfoque ofrece una herramienta versátil para investigaciones que requieren datos anónimos y escalables, respetando patrones demográficos reales.

Keywords: Datos sintéticos · Datos poblacionales · Población Española · Ingeniería de Datos

1. Introducción

El uso de datos personales plantea un desafío complejo en su tratamiento. La mayoría de datos que se ofrecen de personas son datos provenientes de estadísticas, como el Instituto Nacional de Estadística [9], o administraciones que ofrecen datos abiertos, como el portal institucional de datos del Gobierno de España [17]. En ocasiones, disponer de información completa sobre personas, desde

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

su nombre, apellidos o dirección postal, puede ser una cuestión muy relevante para experiencias relacionadas con estudios poblacionales, como el estudio de flujos poblacionales, epidemiología, división de la población en términos geográficos, o en la elaboración de diversas experiencias que requieran identificación de personas, como la generación sintética de documentos de identidad [1].

Algunos autores en la literatura también han propuesto la generación de conjuntos de datos que simulen poblaciones. Rinner et al. [19] presentan una población sintética explícita de EE.UU. para 2019, con 120.754.708 hogares y 303.128.287 individuos, generada mediante ajuste proporcional microdatos del Censo, destacando su utilidad en modelado epidemiológico, social y de políticas públicas. Tiempo atrás, Beckman et al. [2], desarrollaron métodos para crear poblaciones sintéticas usando ajuste proporcional iterativo, sentando bases para generar datos espaciales realistas en estudios de transporte y epidemiología. Posteriormente, Grefenstette et al. [3] presentaron FRED, un modelo epidémico basado en poblaciones sintéticas espacialmente explícitas, destacando su utilidad para simular brotes y estrategias de salud pública. Por su parte, Prédhumeau y Manley [18] propusieron métricas de validación para poblaciones sintéticas, enfocándose en correlaciones y errores relativos, aplicables a evaluaciones de precisión en datos demográficos y espaciales.

Este trabajo propone la generación de datos personales y poblaciones sintéticas simulando el comportamiento de la población española. La creación de una población sintética requiere incluir los municipios de España, mientras que los perfiles personales requieren un conjunto simplificado de datos útil para realizar estudios con personas. En esa línea, este trabajo propone:

1. Construir una población sintética simplificada con vínculos entre poblaciones, hogares y personas.
2. Tres diferentes aproximaciones de generación de perfiles personales sintéticos.

A continuación, se indica la estructura del trabajo: en la segunda sección se explica los datos requeridos, la obtención de datos y su almacenamiento; en la tercera sección, se explica las diferentes aproximaciones de generación y las relaciones; en la cuarta sección, se discuten los resultados obtenidos por las experiencias; y en la quinta sección, se presentan las conclusiones del trabajo.

2. Metodología

En el ámbito de la identidad personal, obtener grandes volúmenes de datos es un arduo trabajo que, en ocasiones, puede abocar en la vulneración de la privacidad y la gestión ética de la información recopilada. Estos casos motivan a realizar metodologías que permitan generar datos personales anonimizados y agregados, con tal de no poder identificar la casuística de ningún sujeto.

La metodología va a plantear la generación de poblaciones sintéticas en base a las distribuciones estadísticas del Instituto Nacional de Estadística. En esta sección, se va a desarrollar el conjunto de características personales a generar y sus relaciones, así como, las diferentes experiencias generativas realizadas.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

2.1. Datos personales

Un individuo puede ser reducido a un conjunto de datos tan amplio como para identificarlo inequívocamente. Esto se puede conseguir con tal solo un identificador que garantice unicidad. El resto de datos pueden otorgar información adicional que puede ser relevante para diferentes usos: movimientos poblacionales, análisis político, renta per cápita, ascendencia y descendencia,... y otros casos que evoquen a cualquier proceso en los que un individuo pueda clasificarse. En función de las necesidades se pueden discernir diferentes grupos de datos personales, aunque principalmente este estudio va a tratar los datos contenidos en un documento nacional de identidad junto a los ingresos personales.

Los datos contenidos en un documento nacional de identidad se pueden clasificar en elementos de identificación personales y elementos de identificación del soporte. Los primeros van a ser aquellos que identifiquen al individuo, y dentro de esta categoría se pueden nombrar aquellos como: nombre, apellidos, fecha de nacimiento, sexo, municipio de residencia, edad o progenitores, entre otros. Por otro lado, los elementos de identificación del soporte son aquellos que permiten identificar una tarjeta de un Documento Nacional de Identidad. Su función es asegurar y controlar la integridad documental del mismo.

De la misma manera, es interesante analizar y generar los ingresos per cápita de las personas, el nivel de estudios o la distribución de hogares.

Para las experiencias a realizar en este trabajo, se va a generar perfiles personales que contengan los siguientes extremos: nombre, primer apellido, segundo apellido, género, municipio de residencia, provincia del municipio de residencia, Comunidad Autónoma del municipio de residencia, edad del individuo e ingresos. La justificación de elección de dichos datos persigue obtener una identificación clara de la persona adaptada al sistema español -*nombre con dos apellidos*-, género de la persona, residencia, ingresos y edad. Se calcula la edad en vez de la fecha de nacimiento para evitar la obsolescencia de las experiencias, conservando los datos generados de forma estática y asociados a la fecha de generación.

2.2. Fuente de datos personales

Los datos generados para un perfil personal deben contener datos relevantes y originales, consiguiendo un reflejo del estado de la población española. Con este fin, se quiere recurrir a los estudios del Instituto Nacional de Estadística para obtener datos y distribuciones estadísticas con alta reputación y confiables sobre la población española.

El primer conjunto de datos que se extrae del Instituto Nacional de Estadística es la relación de nombres. Esta relación de nombres recoge todos los nombres de la población española cuya frecuencia es mayor a 20 repeticiones, junto a su edad media y frecuencia. Asimismo, existe una relación de nombres para cada sexo -*masculino y femenino*-.

El segundo conjunto de datos corresponde con la relación de apellidos con una frecuencia superior a 20 de personas en España, tanto en primera como en segunda posición, e incluida la repetición de ambos.

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

El otro conjunto de datos a emplear lo constituyen la relación de municipios, provincias y comunidades autónomas de España. En este conjunto de datos se encuentra el nombre del municipio y los códigos de provincia y comunidad autónoma al que pertenece.

Del Instituto Nacional de Estadística también se deben obtener otros datos que permitan cuantificar la distribución poblacional, tanto por género, como por edad. La pirámide poblacional a 1 de enero de 2024 [3], la última disponible a fecha de realización de este trabajo, arroja el total de población que se puede apreciar en la Tabla 1.

Tabla 1. Datos de población de España a 1 de enero de 2024.

Género	Personas	Porcentaje
Mujeres	24.792.824 personas	50,99 %
Hombres	23.826.871 personas	49,01 %
Total	48.619.695 personas	100 %

Los datos de población por municipios de España también son extraídos del Instituto Nacional de Estadística. Estos datos permiten conocer cómo está distribuida la población española a lo largo de todo el territorio, así como obtener datos personales acordes con los fenómenos poblacionales españoles. Estos datos son obtenidos por cada uno de los municipios y por género.

Es una cuestión relevante obtener la renta por persona asociada a cada municipio, pues de esta forma se conserva el nivel económico de cada población. Los datos proporcionados por el Instituto Nacional de Estadística ocultan determinada información sobre la renta de los municipios más pequeños, con el fin de evitar obtener información sobre los percentiles más elevados de renta. Para impedir que falten datos en el procesamiento de información de renta, se referirán los términos de renta a nivel provincial, en aquellos supuestos que los datos municipales no estén disponibles. Los datos disponibles están conformados por la media y mediana de renta por unidad de consumo. Una unidad de consumo es referida a un individuo de cada uno de los hogares, con esto se consigue normalizar y homogeneizar los ingresos de los hogares entre todos sus miembros.

Por último, también se obtienen del Instituto Nacional de Estadística la distribución de tipos de hogares número de personas por hogar. Los hogares que se distinguen son de una, dos, tres, cuatro y cinco o más personas.

En el siguiente listado se resumen las colecciones de datos obtenidas del Instituto Nacional de Estadística:

- Todos los nombres con frecuencia igual o mayor a 20 personas. Este fichero contiene nombres de hombres y mujeres por separado [15].
- Lista de apellidos con frecuencia igual o mayor a 20 personas [10].
- Relación de provincias por comunidades autónomas y sus códigos [14].

[3] `https://www.ine.es/jaxiT3/Tabla.htm?t=56935&L=0`

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

- Municipios por provincia con sus códigos [11].
- Población residente por fecha, sexo y generación [12].
- Cifras oficiales de población de los municipios españoles [6].
- Indicadores de renta media y mediana [8] y Porcentaje de población con ingresos por unidad de consumo por debajo/encima de determinados umbrales relativos por sexo [13].
- Hogares por municipio y tamaño del hogar [7].

Estos conjuntos de datos son procesados para generar información aleatoria en base a las directrices impuestas por las experiencias. La limpieza de estos datos se realiza empleando la librería Pandas [16,20] para operar los datos y agregarlos en función de las necesidades de las experiencias. La librería Numpy [4] permite operar y obtener diferentes distribuciones estadísticas en base a los datos de entrada. Por último, Matplotlib [5] permite la visualización de los datos de población, de renta y las gráficas del ajuste de las diferentes distribuciones probabilísticas a los datos.

2.3. Almacenamiento de perfiles personales

Para almacenar la estructura de datos asociada a personas, se ha elegido una configuración en una base de datos orientada a grafos. Concretamente, se ha optado por Neo4j, pues permite almacenar y relacionar las diferentes entidades para agrupar y estudiar sus relaciones.

En la población sintética a generar, se integran las entidades que representen personas, hogares, municipios, provincias y comunidades autónomas. Con respecto a las relaciones, se relacionan las personas a municipios u hogares, en función de la experiencia, municipios a provincias, y provincias a regiones.

Almacenar los datos en una base de datos orientada a grafos permite ampliar la información con diferentes relaciones entre personas. Para ello, se podría relacionar personas entre sí, construyendo relaciones familiares –*progenitor, antecesor o descendente*–, como árboles genealógicos, o estudiar los movimientos poblacionales entre las diferentes regiones y municipios.

Para iniciar el esquema de datos, se insertan los municipios, provincias y comunidades autónomas de España, junto a las relaciones de pertenencia. Tras esto, se insertan los datos personales de datos generados relacionados a cada municipio. En la Figura 1, se puede observar un grafo que muestra diez municipios de la provincia de Badajoz, el nodo que representa la comunidad autónoma de Extremadura, sus provincias como nodos, Cáceres y Badajoz, así como las relaciones entre todas ellas.

3. Experiencias a realizar

En esta sección se explican los tres enfoques a realizar para la generación de poblaciones sintéticas. Para los tres enfoques se aplican dos técnicas diferentes para la obtención del dato concreto de la persona. La primera técnica corresponde

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

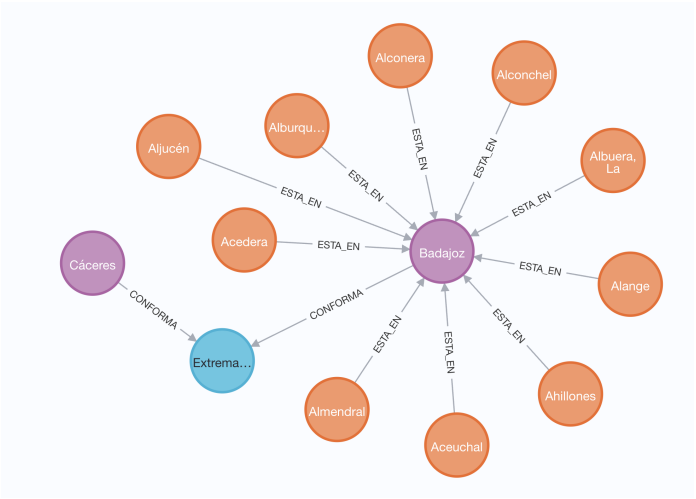

Figura 1. Consulta al grafo con datos de Extremadura y algunos municipios de la provincia de Cáceres

en obtener un dato aleatorio del conjunto de datos en función de su frecuencia de aparición. Para la segunda técnica, se realiza un análisis de la distribución probabilística y se obtiene un dato concreto.

3.1. Distribuciones y generación de datos

Los datos a generar corresponden con los datos asociados a cada persona a modo individual. En función del tipo de dato, se seguirá una u otra técnica para obtenerlo. Los datos a generar se pueden agregar en las siguientes categorías: identificación, residencia, género, ingresos, edad y número de personas por hogar.

Identificación La identificación consiste en asignar un nombre y una pareja de apellidos a la persona sintética. Para obtener estos datos, se va realizar una distribución en base a frecuencias de uso –*número de personas que tienen ese nombre u apellido en una posición determinada*– dentro de la población española. Igualmente, los nombres están clasificados en nombres de hombres y de mujeres, por lo que en función del género asignado, se obtiene la elección del nombre. Con esto, se consigue respetar una distribución conforme a los nombres y apellidos más empleados en España.

Residencia Los datos de residencia consisten en asignar un municipio de residencia a la persona sintética. Para ello, se obtiene el número de población de cada municipio y se realiza una selección aleatoria ponderada a los datos poblacionales. Con esta técnica, se puede obtener una población que respete la distribución poblacional que presenta España.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

Género El género se obtiene mediante una experiencia de Bernoulli. Una primera aproximación consiste en determinar el suceso *ser hombre* o *ser mujer* con una ponderación del 50 % para cada suceso. Para realizar una mejor aproximación, tras la elección del municipio, se calcula el porcentaje de mujeres en esa población. Ese porcentaje se traslada a la probabilidad del suceso *ser mujer* en ese municipio, y el suceso contrario sería *ser hombre*. De esta forma, se busca respetar la distribución estadística de cada municipio.

Edad La obtención de una edad concreta y su asignación a un individuo puede ser realizada mediante el ajuste de una distribución estadística a los datos. Para comprobar un ajuste fidedigno de la distribución poblacional española por edad y género, en la Figura 2 se presenta el ajuste de diferentes curvas.

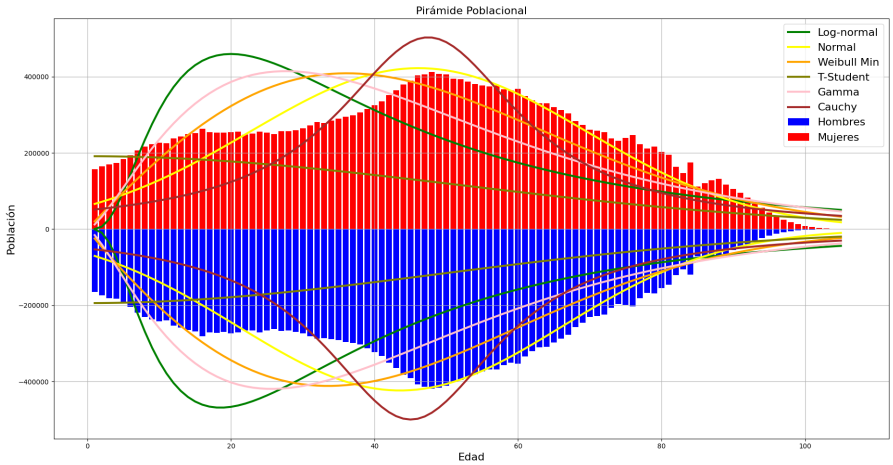

Figura 2. Ajuste de funciones estadísticas a pirámide poblacional española.

Se puede apreciar que el mejor ajuste lo proporciona la distribución normal. Una primera aproximación a la selección aleatoria de la edad viene determinada por obtener un dato aleatorio siguiendo el ajuste de la distribución normal.

Como segunda aproximación, se puede tratar estos datos como el resto de variables y asociar un peso a cada suceso. De esta forma, se hace una elección aleatoria en el intervalo $[0, 105]$ con los pesos asociados a cada género y edad concreta. Cabe destacar que esta elección se realiza tras la obtención del género.

Ingresos Los ingresos por unidad de consumo son calculados mediante la aplicación de una distribución lognormal que ajuste la media y mediana de los ingresos por unidad de consumo de cada municipio. El INE no ofrece los datos correspondientes a la media y la mediana de aquellos municipios con pocos habitantes, poblaciones un número de habitantes tan bajo que se consideran secreto

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

estadístico, en la mayoría de casos, 50 habitantes[4]. En estos casos, se infiere la media y mediana de los ingresos por unidad de consumo para la provincia.

Si se denomina la media como $\bar{x}$ y la mediana como m, se pueden obtener los parámetros de $LogNormal(\mu_x, \sigma_x)$ mediante las Ecuaciones 1 y 2

$$\sigma_x = \sqrt{2 \cdot \ln\left(\frac{\bar{x}}{m}\right)} \tag{1}$$

$$\mu_x = \ln(m) - \frac{\sigma_x^2}{2} \tag{2}$$

Como primera aproximación, se obtienen los parámetros para el ajuste de la media y mediana de los ingresos por unidad de consumo a nivel nacional. En las siguientes aproximaciones, se obtienen los datos correspondientes a cada municipio. Con estas variables, se obtiene un valor aleatorio de esa curva.

Número de personas por hogar La selección del número de personas por hogar viene supeditada por la elección del municipio. Una vez se obtenga un municipio, se realiza una elección en el intervalo $[1, 5]$ de personas. El INE proporciona el número de hogares por cantidad de personas en la clasificación $[1, 4]$ y cinco o más. Para generar hogares con un mayor número de personas a 5, se aplica una distribución Pareto en ese suceso.

La distribución de Pareto permite obtener una extensa cola hacia los valores de la derecha. Para obtener valores en el intervalo $[5, 12]$, se suma a un valor base 5 un resultado aleatorio de la distribución $Pareto(2, 1)$, limitando su valor a 12. De esta forma, se obtiene concentrar los sucesos límite –*hogares con cinco o más personas*– en hogares con un número más bajo de personas, respetando la tendencia de hogares más reducidos observada en la estadística a nivel nacional.

3.2. Ajustes de la primera experiencia

La primera experiencia consiste en una aproximación trivial que obtiene datos de forma aleatoria, teniendo en consideración relaciones muy sencillas. La obtención de cada conjunto de datos de una persona viene dada por los siguientes epígrafes.

- **Identificación**. La identificación de la primera experiencia obtiene los datos del mismo modo que se explica en el apartado anterior.
- **Residencia**. La obtención del municipio se realiza de forma completamente aleatoria, sin disponer de ninguna variable adicional.
- **Género**. El género de una persona se asigna mediante la experiencia Bernoulli(0,5) para el suceso *ser mujer* o *ser hombre*.
- **Edad**. La edad se asigna en función del ajuste de la pirámide poblacional de hombres y mujeres a la normal, la distribución con mejor ajuste a los datos.

[4] `https://www.ine.es/censo_accesible/es/disclaimer.html`

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

- **Ingresos**. Los ingresos son calculados mediante una lognormal ajustada con los datos de media y mediana de renta por unidad de consumo para el año 2023.
- **Número de personas por hogar**. No aplica para esta experiencia, pues no se obtienen hogares.

3.3. Ajustes de la segunda experiencia

En la segunda experiencia, se emplea la elección de variables aleatorias siguiendo los pesos ponderados a cada uno de los sucesos, tal y como se presenta en el primer experimento con la elección de nombres y apellidos.

- **Identificación**. La identificación se realiza igual que en la primera experiencia.
- **Residencia**. El municipio de residencia es elegido mediante una distribución que ajusta con los habitantes de cada municipio como frecuencia.
- **Género**. Se emplea la probabilidad de *ser mujer* como el porcentaje de la población española de sexo femenino, y el suceso contrario, *ser hombre*.
- **Edad**. La edad se ajusta a la población española, por lo que se hace una elección de sucesos ponderados por la frecuencia de cada ocurrencia.
- **Ingresos**. Se aplica una distribución lognormal con la media y mediana marcada por los ingresos obtenidos por hombres o mujeres, en función del género asignado.
- **Número de personas por hogar**. Al igual que en la primera experiencia, no aplica este parámetro, pues no se forman hogares.

3.4. Ajustes de la tercera experiencia

La tercera experiencia incorpora la relación de personas en hogares, permitiendo escalar los vínculos creados. Asimismo, respeta el uso de distribuciones basadas en frecuencia, permitiendo simular el comportamiento de la población española. Las características de los datos vienen dadas por:

- **Identificación**. La identificación se realiza de misma forma a las otras dos experiencias.
- **Residencia**. La residencia se ajusta al método de selección de la experiencia anterior.
- **Género**. Para estimar el suceso *ser mujer*, se emplea el porcentaje de mujeres sobre el total de personas del municipio. El suceso contrario es *ser hombre*.
- **Edad**. La edad se obtiene de forma análoga a la experiencia anterior.
- **Ingresos**. Se aplica una distribución lognormal con la media y mediana marcada por los ingresos por unidad de consumo del municipio. En caso de que esos datos no figurasen, se emplean los datos provinciales.
- **Número de personas por hogar**. El número de personas por hogar viene determinado por una elección ponderada de los datos obrantes para cada municipio, tal y como se indica en el primer apartado de la sección.

En la Tabla 2, se recoge un resumen de los métodos aplicados a cada experiencia.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

Tabla 2. Resumen de la elección de variables en cada experiencia

Variable	Experiencia 1	Experiencia 2	Experiencia 3
Identificación	Elección por frecuencia		
Residencia	Aleatorio	Elección por habitantes	
Género	$Bernoulli(0,5)$	Bernoulli población país	Bernoulli población municipio
Edad	Ajuste a normal	Pirámide poblacional	
Ingresos	Ingresos nacionales	Ingresos nacionales y sexo	Ingresos por municipio
Nº de personas / hogar	No aplica		Elección por frecuencia

4. Resultados

En esta sección se discuten los resultados obtenidos, así como se muestra el rendimiento y calidad obtenidos a la hora de generar cien mil perfiles mediante las diferentes experiencias. Las pruebas han sido realizadas sobre un MacBook Pro M4 Pro con 24GB de RAM. Para realizar estas experiencias, se ha empleado Python 3.10 para generar y ejecutar las consultas contra la base de datos. La base de datos es independiente para cada experiencia y está desplegada sobre Docker, empleando la imagen Neo4j 5.26-enterprise.

4.1. Generación y almacenamiento de las poblaciones

Este apartado tiene como objetivo mostrar el coste computacional de generar una población de cien mil personas. Este coste computacional se va a medir en dos variables: tamaño de la base de datos y el tiempo que se tarda en generar y añadir esos datos en una base de datos Neo4j. En la Tabla 3 se puede observar el coste computacional en tiempo y almacenamiento que tiene la base de datos.

Tabla 3. Coste computacional por experiencia sobre población de 100000 individuos.

Variable analizada	Experiencia 1	Experiencia 2	Experiencia 3
Tiempo (s)	460,15	390,65	524,84
Almacenamiento (MB)	17,1	17,6	22,2

4.2. Muestra y calidad de los datos obtenidos

La calidad de los datos obtenidos se puede obtener en base al estudio del comportamiento de la población obtenida con la población real española. Para cada una de las experiencias, se toman los datos de ingresos económicos, sexo, edad y municipios, así como, para la tercera experiencia, el nº de personas/hogar.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

Para analizar los ingresos económicos, se obtiene la media y mediana de las personas generadas y se aplican las Ecuaciones 1 y 2, enfrentando la distribución obtenida con la distribución de entrada, correspondiente con los datos del INE. Este análisis se puede comprobar en la Figura 3.

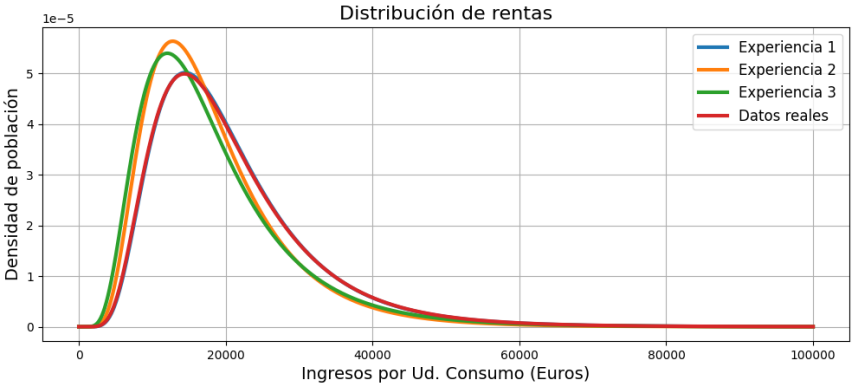

Figura 3. Distribución lognormal media de rentas para las experiencias y real.

El análisis de edad y sexo se realiza de forma conjunta. Se comparan los valores normalizados entre la población sintética y real con determinado sexo y edad. Para esta distribución, se representan las curvas de las tres experiencias y real, distinguidas por género. Este resultado puede comprobarse en la Figura 4.

De forma análoga, se busca respetar la distribución de población española a lo largo de su geografía. Por ello, se agregan las personas generadas en regiones, comparando los resultados de población real normalizada frente a los de la población sintética. Este resultado se puede apreciar en la Figura 5. De este resultado cabe destacar que, para la primera experiencia, Castilla y León tiene la mayor población porque el suceso de elegir un municipio es equiprobable. Como esta región tiene el mayor número de municipios de España, una mayor cantidad mayor de personas forman esta Comunidad Autónoma.

Por último, para la tercera experiencia, se enfrenta la distribución nacional de personas por hogar frente al agregado de datos obtenido en la población sintética. Este resultado puede observarse en la Figura 6.

Los resultados reflejados en las Figuras demuestran la exactitud del comportamiento poblacional con un conjunto muy reducido de individuos generados –100.000– Se consigue replicar el comportamiento de la población para aquellas variables más interesantes: ingresos, edad, género y tamaño de hogares.

La mayor expresividad de entre las tres experiencias la aporta la tercera aproximación. Tener en cuenta el número de personas por hogar permite estudiar relaciones inter e intrafamiliares, así como, su relación con el entorno, disponiendo de un conjunto de datos más eficaz para temas de estudios y víncu-

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

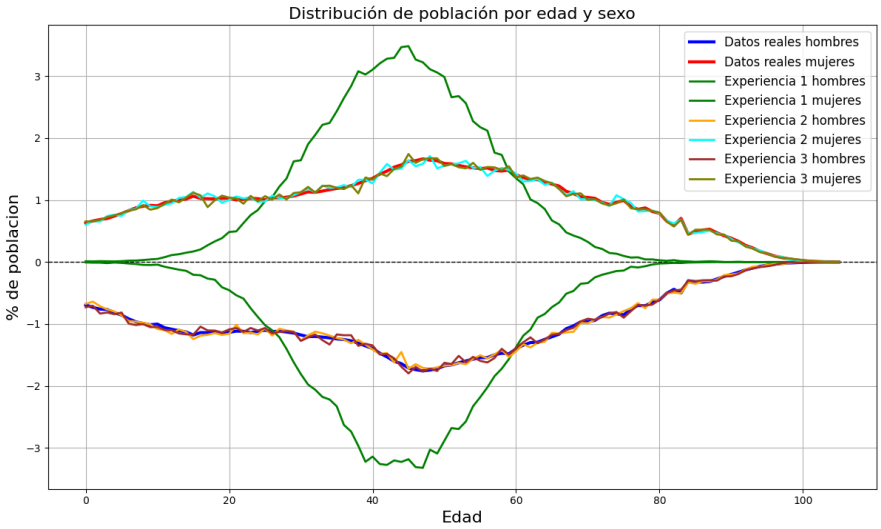

Figura 4. Distribución de población de experiencias por edad y sexo frente a población real

los poblacionales. La segunda y tercera experiencia tienen mejores resultados, pues teniendo ciertas variables en consideración, se puede obtener una población que tenga un comportamiento similar a la dada, en este caso, la población española. Igualmente, considerar variables como el municipio, la edad o el género, es útil para obtener un comportamiento poblacional similar sobre el real.

5. Conclusiones

La generación de poblaciones sintéticas mostrada en este trabajo, y realizada mediante procesos de ingeniería de datos, permite la obtención de datos personales no vinculados a ningún individuo concreto. De misma forma, permite disponer grandes volúmenes de datos para realizar estudios que impliquen el uso de datos personales. Las tres experiencias descritas a lo largo del trabajo presentan diferentes aproximaciones de cómo guiar la generación de datos sintéticos personales, simulando los comportamientos que una población real tiene. Estas experiencias pueden ser aumentadas para añadir diferentes datos, e incluso, estudiar los vínculos y trazabilidad entre individuos.

Agradecimientos Cabe destacar que esta iniciativa se realiza en el marco de los fondos del Plan de Recuperación, Transformación y Resiliencia, financiados por la Unión Europea (Next Generation) - Instituto Nacional de Ciberseguridad (INCIBE) en el proyecto C108/23 “Detección de Falsificación de Documentos de Identidad mediante Técnicas de Visión por Computador e Inteligencia Artificial”.

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

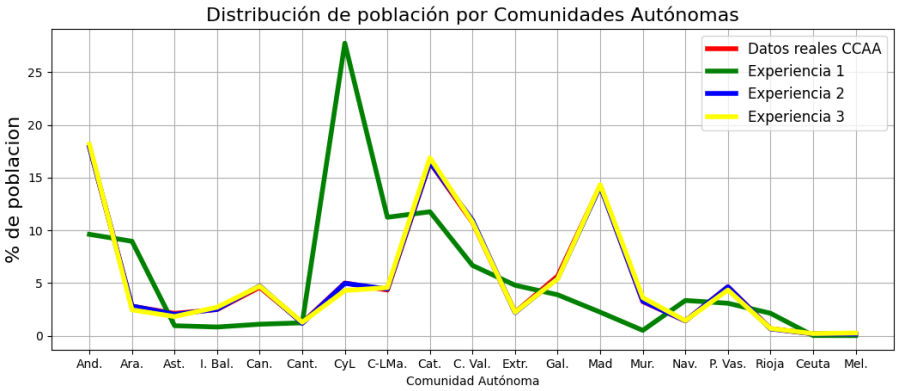

Figura 5. Distribución de la población real y generadas en Comunidades Autónomas.

Declaración de intereses Los autores no tienen intereses en competencia que declarar que sean relevantes para el contenido de este artículo.

Referencias

1. Amores Chaparro, V., Broncano Morgado, F., Hernández Martín, A., Mogollón Gutiérrez, O., J Sancho Núñez, J.C., Pais, S.: Generación de Documentos Nacionales de Identidad sintéticos mediante el uso de perfiles biográficos. In: IX Jornadas Nacionales de Investigación En Ciberseguridad, (2024)
2. Beckman, R.J., Baggerly, K.A., McKay, M.D.: Creating synthetic baseline populations. Transportation Research Part A: Policy and Practice **30**(6), 415–429 (1996)
3. Grefenstette, J.J., Brown, S.T., Rosenfeld, R., DePasse, J., Stone, N.T., Cooley, P.C., Wheaton, W.D., Fyshe, A., Galloway, D.D., Sriram, A., Guclu, H., Abraham, T., Burke, D.S.: Fred (a framework for reconstructing epidemic dynamics): an open-source software system for modeling infectious diseases and control strategies using census-based populations. BMC Public Health **13**(1), 940 (2013). `https://doi.org/10.1186/1471-2458-13-940`
4. Harris, C.R., Millman, K.J., van der Walt, S.J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N.J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M.H., Brett, M., Haldane, A., del Río, J.F., Wiebe, M., Peterson, P., Gérard-Marchant, P., Sheppard, K., Reddy, T., Weckesser, W., Abbasi, H., Gohlke, C., Oliphant, T.E.: Array programming with NumPy. Nature **585**(7825), 357–362 (Sep 2020). `https://doi.org/10.1038/s41586-020-2649-2`
5. Hunter, J.D.: Matplotlib: A 2d graphics environment. Computing in Science & Engineering **9**(3), 90–95 (2007). `https://doi.org/10.1109/MCSE.2007.55`
6. Instituto Nacional de Estadística: Cifras oficiales de población de los municipios españoles, `https://www.ine.es/pob_xls/pobmun.zip`, visitado 28 de feb. de 2025
7. Instituto Nacional de Estadística: Hogares por municipio y tamaño, `https://www.ine.es/jaxi/files/tpx/es/xlsx/59543.xlsx`, visitado 28 de feb. de 2025
8. Instituto Nacional de Estadística: Indicadores de renta media y mediana, `https://ine.es/jaxiT3/files/t/es/xlsx/53689.xlsx`, visitado 28 de feb. de 2025

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.

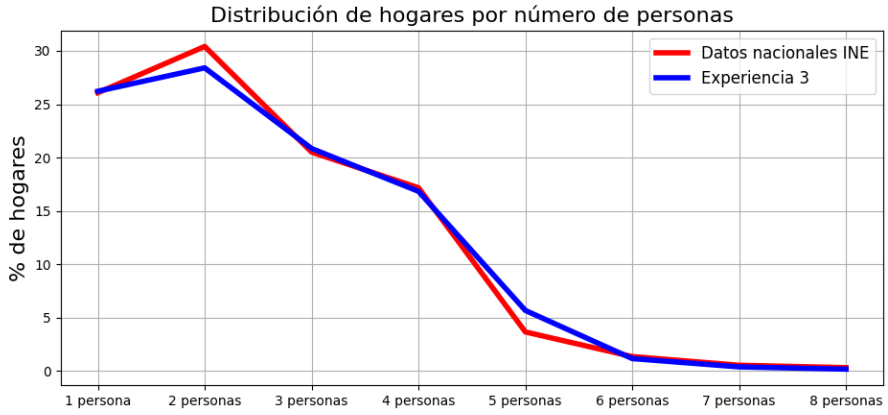

Figura 6. Distribución de número personas por hogar.

9. Instituto Nacional de Estadística: Instituto nacional de estadística, `ine.es`
10. Instituto Nacional de Estadística: Lista de apellidos con frecuencia igual o mayor a 20 personas, `https://www.ine.es/daco/daco42/nombyapel/apellidos_frecuencia.xls`, visitado 28 de feb. de 2025
11. Instituto Nacional de Estadística: Municipios por provincia con sus códigos, `https://www.ine.es/daco/daco42/codmun/25codmun.xlsx`, visitado 28 de feb. de 2025
12. Instituto Nacional de Estadística: Población residente por fecha, sexo y generación (edad a 31 de diciembre), `https://www.ine.es/jaxiT3/files/t/es/xlsx/56935.xlsx`, visitado 28 de feb. de 2025
13. Instituto Nacional de Estadística: Porcentaje de población con ingresos por unidad de consumo por debajo/encima de umbrales relativos por sexo, `https://ine.es/jaxiT3/files/t/es/xlsx/53694.xlsx`, visitado 28 de feb. de 2025
14. Instituto Nacional de Estadística: Relación de provincias por comunidades autónomas y sus códigos, `https://www.ine.es/daco/daco42/codmun/cod_ccaa_provincia.htm`, visitado 28 de feb. de 2025
15. Instituto Nacional de Estadística: Todos los nombres con frecuencia igual o mayor a 20 personas, `https://www.ine.es/daco/daco42/nombyapel/nombres_por_edad_media.xlsx`, visitado 28 de feb. de 2025
16. Wes McKinney: Data Structures for Statistical Computing in Python (2010). `https://doi.org/10.25080/Majora-92bf1922-00a`
17. Ministerio para la Transformación Digital y de la Función Pública: Datos abiertos del gobierno de españa, `https://datos.gob.es`, visitado 5 de mar. de 2025
18. Prédhumeau, M., Manley, E.: A synthetic population for agent-based modelling in canada. Scientific Data **10**(1), 148 (2023). `https://doi.org/10.1038/s41597-023-02030-4`
19. Rineer, J., Kruskamp, N., Kery, C., Jones, K., Hilscher, R., Bobashev, G.: A national synthetic populations dataset for the united states. Scientific Data **12**(1), 144 (2025). `https://doi.org/10.1038/s41597-025-04380-7`
20. The Pandas Development Team: pandas-dev/pandas: Pandas (Feb 2020). `https://doi.org/10.5281/zenodo.3509134`

Broncano Morgado, F., Sequera Fernández, M. J., Mogollón Gutiérrez, Ó., Homaei, M., García Rodríguez, P.: Generación y Estudio de una Población Sintética Española mediante Ingeniería de Datos. In: Burgueño, L. (ed.) Actas de las XXIX Jornadas de Ingeniería del Software y Bases de Datos (JISBD 2025). Sistedes (2025). https://hdl.handle.net/11705/JISBD/2025/111

Esta obra está bajo una licencia Creative Commons “Atribución-NoComercial-SinDerivadas 4.0 Internacional”.