ESCUELA POLITÉCNICA

UNIVERSIDAD DE EXTREMADURA

Escuela Politécnica

Máster universitario en Ingeniería Informática

Trabajo Fin de Máster

Técnicas avanzadas para la generación y detección de Documentos de Identidad sintéticos

UNIVERSIDAD DE EXTREMADURA

Escuela Politécnica

Máster universitario en Ingeniería Informática

Trabajo Fin de Máster

Técnicas avanzadas para la generación y detección de Documentos de Identidad sintéticos

Autor: Kevin Amores Chaparro

Tutor: José Carlos Sancho Núñez

Co-Tutor: Álvaro Hernández Martín

Resumen

Cada vez son más comunes los servicios online ofertados por empresas, como banca online. Para ello, deben implementar sistemas de autenticación y verificación con el fin de comprobar que el usuario está intentando acceder a los servicios de forma legítima.

Uno de los sistemas más comunes de autenticación es el uso de los documentos de identidad, aportando pruebas en forma de foto o vídeo. El sistema entonces revisa el vídeo, tomando como referencia ciertas medidas de seguridad que utilizn los DNI para certificar su identidad, tales como kinegramas o tintas ópticamente variables.

Sin embargo, usuarios maliciosos podrían buscar medios de burlar dichas medidas de seguridad, ya sea creando documentos de identidad falsos, manipulando ya existentes, o incluso modificando la imagen por ordenador. Por ello, los sistemas deben analizar las imágenes con detalle y detectar las falsificaciones.

En este documento, se exponen algunas de las medidas de seguridad de los documentos de identidad y de las pruebas grabadas y se explican métodos para analizarlos y distinguir los documentos legítimos de los falsos. Además, se exponen posibles métodos de generación de documentos falsos con el fin de atacar al sistema.

Palabras clave: documento de identidad, detección de ataques, biometría, visión artificial

Abstract

The online services offered by companies, such as online banking, are becoming increasingly common. In order to do so, they must implement authentication and verification systems to ensure that the user is attempting to access the services legitimately.

One of the most common authentication systems is the use of identity documents, providing evidence in the form of a photo or video. The system then reviews the video, using certain security measures that ID cards employ to certify their identity, such as kinegrams or optically variable inks.

However, malicious users may seek ways to bypass these security measures, whether by creating fake identity documents, manipulating existing ones, or even altering the image using a computer. Therefore, the systems must analyze the images in detail and detect forgeries.

This document presents some of the security measures of identity documents and recorded evidence, and explains methods for analyzing them and distinguishing legitimate documents from fakes. Additionally, possible methods of generating fake documents in order to attack the system are discussed .

Keywords: identity document, attack detection, biometrics, computer vision

Índice general

1. Introducción **1**
1.1. Contribuciones 4
1.2. Planificación 4
1.3. Estructura del trabajo 5

2. Objetivos **7**

3. Estado del Arte **9**
3.1. Marco teórico 9
3.1.1. Visión artificial 10
3.1.2. Aprendizaje automático 13
3.1.3. Aprendizaje profundo 15
3.2. Tecnologías usadas 19
3.3. Trabajos relacionados 21
3.3.1. Digital Image Watermarking for Photo Authentication in Thai national ID card 21
3.3.2. Pixel-wise supervision for presentation attack detection on identity document cards 22
3.3.3. Towards Efficient and Scale-Robust Ultra-High-Definition Image Demoiréing 23
3.3.4. Synthetic ID Card Image Generation for Improving Presentation Attack Detection 24
3.3.5. Face Image Quality Vector Assessment for Biometrics Applications 25
3.3.6. A masked-face detection algorithm based on M-EIOU loss and improved ConvNeXt 27

3.3.7. Desarrollo de un aplicativo móvil para la extracción automática de información del documento de identificación mediante visión computacional . . . 27

4. Material y Método **29**
4.1. Detección de kinegrama . . . 30
4.2. Reconocimiento de texto . . . 31
4.3. Identificación de tipo de DNI . . . 32
4.4. Detección de moiré . . . 34
4.5. Estimación de calidad de imágenes de personas . . . 36
4.6. Gafas . . . 39
4.7. Generación de DNI sintéticos . . . 40

5. Resultados y discusión **47**
5.1. Detección de kinegrama . . . 47
5.2. Reconocimiento de texto . . . 50
5.3. Identificación de tipo de DNI . . . 51
5.4. Detección de moiré . . . 52
5.5. Estimación de calidad de imágenes de personas . . . 54
5.6. Gafas . . . 55
5.7. Generación de DNI sintéticos . . . 57

6. Conclusiones y trabajos futuros **61**

Anexos **65**

A. Características del DNI **65**
A.1. DNI Franquista . . . 65
A.2. Primer DNI informatizado . . . 66
A.3. DNIe . . . 67
A.4. DNI 3.0 . . . 68
A.5. DNI 4.0 . . . 71

B. Estándares de fotografías para carnet **73**

Bibliografía **76**

Índice de tablas

1.1. Resumen de la planificación 5

4.1. Conjuntos de datos utilizados 29
4.2. Características de los equipos utilizados 29
4.3. Métricas utilizadas para la evaluación de clasificadores 30
4.4. Resultados del entrenamiento para detección de moiré 36
4.5. Formatos de los campos que siguen un formato concreto 41

5.1. Resultados de si se ha leído el dato correctamente 50
5.2. Frecuencias relativas con las que se han leído los resultados correctos 51
5.3. Resultados del entrenamiento de clasificador de DNI 51
5.4. Resultados del entrenamiento para detección de moiré 52
5.5. Resultados del detector de gafas 55
5.6. Puntuaciones de las imágenes usadas en los DNI 58

A.1. Letra del DNI 65

Índice de figuras

1.1. Ejemplos de falsificación del DNI 3

3.1. Ejemplo de imagen con ruido siendo restaurada 11
3.2. OCR 12
3.3. Estructura básica de una red neuronal 16
3.4. Ejemplo de red neuronal convolucional 17
3.5. Estructura de una red neuronal generativa antagónica 18
3.6. Esquema de funcionamiento de la marca de agua 22
3.7. Estructura del modelo 23
3.8. Ejemplo de foto antes y después del filtro 24
3.9. Ejemplos de DNI generados artificialmente 25
3.10. Arquitectura de la red neuronal multitarea 26

4.1. Ejemplo de reconocimiento de texto 32
4.2. Estructura de la red neuronal utilizada 33
4.3. Ejemplos de DNI y sus tipos 34
4.4. Ejemplo de DNI con moiré 34
4.5. Ejemplo de cálculo de rotación de una cara 37
4.6. Ejemplo de cálculo de apertura de ojos y boca 38
4.7. Ejemplo de cálculo de distancia de ojos a bordes 39
4.8. Muestras del conjunto de datos 40
4.9. MRZ de los documentos de viaje 1 42
4.10. Foto antes y después de los filtros 43
4.11. Foto antes y después de los filtros 43
4.12. Trazos especiales de la fuente 44
4.13. Foto antes y después de los filtros 44

4.14. Ejemplos de muestras del conjunto de datos 45

5.1. Ejemplo de detección de kinegrama 48
5.2. Gráficos de precisión de detección de DNI 49
5.3. Matriz de confusión del detector del tipo de DNI 52
5.4. Ejemplo de detección de imagen limpia 53
5.5. Ejemplo de detección de imagen con moiré 54
5.6. Ejemplos de estimaciones de imágenes 54
5.7. Matriz de confusión de identificación de gafas 55
5.8. Ejemplo de predicción 56
5.9. ¿Lleva o no gafas? 57
5.10. DNI 3.0 sintéticos 57
5.11. DNI 3.0 real 58
5.12. DNI 4.0 sintéticos 58
5.13. DNI 4.0 real 58
5.14. DNI 3.0 reverso sintéticos 58
5.15. DNI 3.0 reverso real 59
5.16. DNI 4.0 reverso 59
5.17. DNI 4.0 reverso real 59

A.1. DNI franquista 66
A.2. DNI 1.0 67
A.3. Medidas de seguridad del DNIe 68
A.4. Campos del DNI 3.0 69
A.5. Medidas de seguridad del DNI 3.0 71
A.6. Medidas de seguridad del DNI 4.0 72

B.1. Ejes de rotación de la cabeza 74
B.2. Exposición de una imagen 75

Capítulo 1

Introducción

Cada vez son más comunes los servicios digitales ofertados por las granes empresas. Abarcan servicios como compra online, carteras de criptomoneda, banca, etc. A fin de que una persona pueda identificarse y demostrar su identidad, con el fin de acceder a dichos servicios de forma segura y legítima, las empresas que ofertan dichos servicios incorporan sistemas de autenticación que demuestren que el usuario que está intentando registrarse es una persona con intenciones legítimas.

Para ello, los sistemas informáticos implementan identificación basada en varias técnicas para acreditar la identidad del usuario, como pueden ser certificados digitales o cargos monetarios en su tarjeta de crédito por un importe simbólico.

Uno de los más comunes es el uso de los documentos de identidad, solicitando al usuario una prueba visual de que posee un documento que demuestre su identidad. Este método es relativamente sencillo, pues solo requiere del usuario un documento de identidad y una cámara o escáner (y los teléfonos inteligentes poseen cámaras integradas).

Sin embargo, también cabe la posibilidad de que los usuarios maliciosos traten de sortear dichos sistemas de seguridad. Esto sucede con frecuencia al igual que en todo tipo de sistemas informáticos y puede permitir a los usuarios saltar los procesos de acreditación de identidad, registrarse múltiples veces o con una identidad falsa, etc.

En el caso de los documentos de identidad, existen diferentes técnicas para falsificar los propios documentos, creando documentos falsificando o modificando los ya existentes con datos falsos. Además, pueden tratar de modificar las imágenes resultantes para cambiar los datos digitalmente, introducir ruido, etc.

Por ello, los sistemas informáticos que implementen autenticación usando pruebas visuales deben implementar medidas para detectar posibles falsificaciones o intentos de engañar al algoritmo. Estos pueden ir desde documentos falsificados impresos, ediciones de documentos originales, documentos robados, ediciones digitales de las pruebas visuales, etc.

Las pruebas consisten en un vídeo corto donde el usuario muestra su documento y lo rota ligeramente para dejar al descubierto todas las medidas del documento.

Los algoritmos entonces analizan los cambios en el vídeo para comprobar si las medidas de seguridad se comportan como deberían (tales como kinegramas que cambian de color). Además, rastrear el documento de identidad y analizar tanto sus datos como posibles artefactos de edición o ruido que puedan indicar un posible ataque.

Asimismo, sería interesante conocer las técnicas utilizadas para la falsificación de documentos de identidad para conocer más sobre ellas y desarrollar contramedidas para detectarlas, como en el caso de la figura 1.1.

Figura 1.1: Ejemplos de falsificación del DNI

Fuente: Público

Otro de los factores que hacen tan importante la validación de los documentos de identidad es la suplantación de identidad. La suplantación de identidad es un delito en el cual una persona se hace pasar por otra, utilizando información personal y datos sensibles sin el consentimiento de la persona afectada. Esta práctica tiene como objetivo obtener beneficios ilegales, como acceso a cuentas bancarias, obtención de créditos, realizar compras fraudulentas o cometer otros actos delictivos en nombre de la víctima.

El robo de identidad puede tener lugar de varias formas. Algunas de las más comunes incluyen:

- Robo de documentos: Los delincuentes pueden obtener acceso a documentos personales, como pasaportes, tarjetas de identificación, licencias de conducir o estados de cuenta bancarios, para utilizar esa información en su beneficio.

- Phishing: Esta técnica implica el envío de correos electrónicos o mensajes de texto fraudulentos que parecen provenir de instituciones legítimas, como bancos o empresas de servicios, solicitando información personal o financiera. Los estafadores utilizan estos datos para suplantar la identidad de la víctima.

- Skimming: Consiste en la instalación de dispositivos ilegales en cajeros

automáticos, terminales de punto de venta u otros lugares donde se realicen transacciones con tarjetas de crédito o débito. Estos dispositivos capturan la información de las tarjetas, permitiendo a los delincuentes crear copias y utilizarlas posteriormente.

- Robo de información en línea: Los hackers pueden acceder a bases de datos en línea, redes sociales o cuentas de correo electrónico para obtener datos personales valiosos que les permitan suplantar la identidad de alguien.

Este delito ha aumentado con el avance de la tecnología y el uso generalizado de Internet. De hecho, se estima que, en España, el 7 % de la población ha sido víctima de suplantación de identidad [1], siendo el país de la Unión Europea con mayores ocurrencias de este delito.

1.1. Contribuciones

Las contribuciones principales de este trabajo son:

- Creación de un modelo que permite la identificación del kinegrama en una imagen o vídeo de un documento de identidad español mediante aprendizaje profundo.

- Creación de un algoritmo de generación de documentos de identidad sintéticos de manera automática y con datos aleatorios pero congruentes, alimentado por una serie de conjuntos de datos y de imágenes.

- Confección de un prototipo de modelo estimador de calidad de fotografía de personas con relación a los estándares de foto carnet, extrayendo algunas de sus características aplicando visión artificial y generando valor unificado de calidad para cada imagen.

1.2. Planificación

La planificación de tareas es la siguiente:

- Detección de kinegrama: algoritmo de detección de dicha medida de seguridad

en vídeos de documentos de identidad (30 h).

- Reconocimiento de caracteres: algoritmo de segmentación y lectura de datos personales contenidos en fotos o vídeos de documentos de identidad (20 h).
- Generación de documentos de identidad falsos: programa que genera documentos de identidad sintéticos a partir de un repositorio de fotografías y de una serie de datos personales generados aleatoriamente (90 h).
- Detección de tipo de DNI: modelo que clasifique imágenes de DNI según el tipo al que pertenecen (15 h).
- Detección de gafas: modelo que detecte si una persona lleva o no gafas (15 h).
- Detección de moiré: modelo que detecte dicho patrón de ruido en la imagen de un DNI (25 h).
- Gestión de calidad de imágenes de personas: algoritmo que mide cuán apropiada es una imagen para ser utilizada en un documento de identidad (40 h).
- Documentación: este punto incluye, pero no limitándose a: estudio del estado del arte y análisis de herramientas y artículos, estudio sobre las características principales de los DNI y de las fotografías tamaño carnet, redacción del documento y confección y recopilación de imágenes (150 h).

El desglose de tiempo se muestra en la tabla 1.1

	07-2022	08-2022	09-2022	10-2022	11-2022	12-2022	01-2023	02-2023	03-2023	04-2023	05-2023	06-2023	07-2023
Kinegrama	12		12	6									
Lectura de caracteres			5	5	5	5							
Detección de tipo de DNI							10	5					
Generación de DNI falsos						20	15	15	10	10	10	10	
Detección de gafas							10	5					
Detección de moiré					20	5							
Calidad de fotos de personas								5	5	10	10	10	
Documentación			10	10	10	10	10	10	10	10	20	20	30

Tabla 1.1: Resumen de la planificación

1.3. Estructura del trabajo

El trabajo se estructura de la siguiente manera:

- En el **capítulo 2: Objetivos** se detallan los objetivos que se plantearon a la hora del desarrollo de dicho proyecto.
- El **capítulo 3: Estado del Arte** resume algunos de los trabajos más importante relaciones con el campo.
- El **capítulo 4: Material y Método** explica cada uno de los apartados en los que ha consistido el proyecto, los materiales y librerías utilizados y los procedimientos llevados a cabo.
- El **capítulo 5: Resultados y discusión** menciona los resultados obtenidos en los puntos desarrollados.
- Por último, en el **capítulo 6: Conclusiones y trabajos futuros** se realiza una síntesis del trabajo y de los puntos trabajados.
- La **bibliografía** enumera todas las referencias utilizadas en este trabajo en formato ISO690.
- El **anexo A: Características del DNI** explica en profundidad las características de los documentos de identidad españoles.
- El **anexo B: Estándares de fotografías para carnet** referencia los requisitdos de calidad que deben cumplir las fotos formato *carnet* para documentos oficiales.

Capítulo 2

Objetivos

El objetivo global trata de indagar en las características principales del DNI y desarrollar una serie de algotimos que puedan identificarlas, tanto sus campos como sus medidas de seguridad.

De ahí se pueden extraer los siguientes objetivos genéricos:

- Crear algoritmos que permitan identificar las medidas de seguridad de los documentos de identidad (como se describen en el anexo A: Características del DNI y discernir los documentos legítimos de los falsos.
- Crear un algoritmo que permita extraer la información de un DNI mediante técnicas de reconocimiento de caracteres. Esto puede servir para validarlos o cotejarlos.
- Crear un algoritmo que permita generar documentos sintéticos en masa.

De estos objetivos generales, concretamos los siguientes objetivos específicos:

- Crear un algoritmo que permita identificar el kinegrama de un vídeo.
- Crear un algoritmo que permita segmentar los datos personales presentes en un DNI y leerlos.

- Crear un algoritmo que identifique el tipo de DNI presente en una imágen.
- Crear un algoritmo que genere documentos de identidad sintéticos a partir de datos generados aleatoriamente correspondiendo a los formatos y valores válidos.

Capítulo 3

Estado del Arte

En los últimos años, campos como la visión artificial o el aprendizaje profundo han evolucionado considerablemente y han permitido el procesamiento de imágenes de nuevas formas. Esto es especialmente útil para la detección de anomalías en imágenes tales como las de documentos de identidad y así aumentar la robustez de los sistemas que dependan de identificación con documentos.

Asimismo, los grandes avances en redes generativas y edición de imágenes, así como la gran cantidad de información disponible en internet ha propiciado el auge de métodos de suplantación de identidad y falsificación de documentos cada vez más sofisticados. Por ello, los desarrolladores e investigadores deben conocerlos y analizarlos en busca de contramedidas que puedan servir para detectar falsificaciones.

En este contexto, se han realizado varias investigaciones en diferentes campos para estudiar medidas de generación de documentos sintéticos o detección de estos.

3.1. Marco teórico

En cuanto a teoría, existen varios avances directamente relacionados con el campo a tratar, que se describen en este apartado.

3.1.1. Visión artificial

La visión artificial es una disciplina informática que abarca los métodos utilizados por los ordenadores para ver, procesar y analizar imágenes extraídas del mundo real con tal de obtener información de estas. La visión artificial se nutre de diferentes campos como la geometría, la estadística o la física. En los últimos años, el aprendizaje automático y el aprendizaje profundo (*deep learning*) han revolucionado la visión artificial. Estas técnicas permiten a los sistemas de visión artificial aprender automáticamente a partir de grandes conjuntos de datos de imágenes, mejorando así su capacidad para reconocer y comprender objetos y escenas complejas.

La visión artificial se basa en algoritmos y técnicas que procesan y analizan imágenes digitales para extraer características y realizar tareas específicas. Estas tareas pueden incluir la detección de objetos, el reconocimiento facial, el seguimiento de objetos en movimiento, la segmentación de imágenes, la clasificación de contenido visual, entre otras.

- **Restauración de imágenes**: Se centra en mejorar la calidad y el aspecto de las imágenes dañadas, deterioradas o de baja calidad. El objetivo principal de la restauración de imágenes es recuperar la información perdida, reducir el ruido, eliminar artefactos y mejorar la claridad y la apariencia visual de las imágenes.

  Existen varios desafíos en la restauración de imágenes, ya que las imágenes pueden verse afectadas por diferentes tipos de degradación, como ruido, borrosidad, falta de contraste, compresión, entre otros.

  La restauración de imágenes abarca una serie de técnicas: reescalado de imágenes y aumento de su resolución y nitidez, mejora de contraste para mejorar su detallado, supresión de ruido y de artefactos de compresión o degradación de imágenes antiguas, etc. Un ejemplo de caso de uso es el programa que se ejemplifica en la figura 3.1.

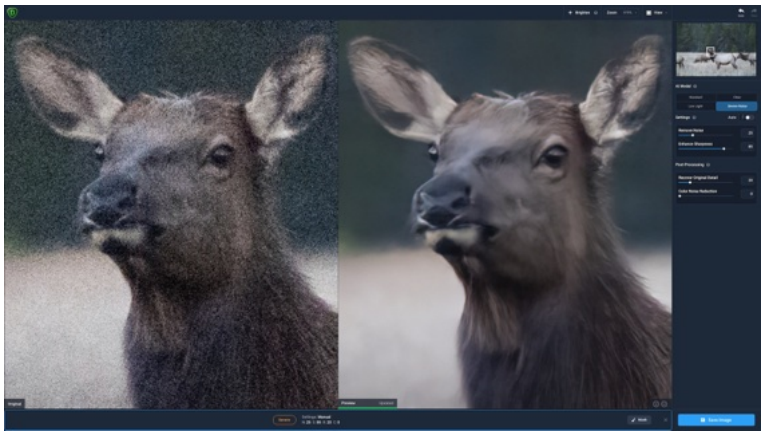

Figura 3.1: Ejemplo de imagen con ruido siendo restaurada

Fuente: TopazLabs

- **Detección de objetos**: se utiliza para identificar y localizar objetos específicos en imágenes o videos.

  Para ello, se extraen características relevantes de la imagen que ayudarán a distinguir los objetos de interés del resto de la escena. Las características pueden ser de diferentes tipos, como bordes, esquinas, texturas o características basadas en la apariencia, como descriptores locales (por ejemplo, SIFT, SURF) o características aprendidas mediante redes neuronales convolucionales (CNN).

  Para reducir la cantidad de regiones de la imagen que deben examinarse exhaustivamente, se utilizan algoritmos de generación de regiones propuestas. Estos algoritmos sugieren regiones que potencialmente contienen objetos, con el objetivo de enfocar la atención en áreas prometedoras. Luego, cada región propuesta se clasifica para determinar si contiene o no un objeto de interés.

  Si se detectan múltiples regiones propuestas que corresponden al mismo objeto, se realiza un ajuste para combinarlas y delimitar una única detección precisa. Esto puede implicar técnicas como el agrupamiento de regiones superpuestas, la eliminación de detecciones redundantes o la estimación de la posición y el tamaño óptimos del objeto.

- **Reconocimiento de texto**: también conocido como reconocimiento óptico de caracteres (OCR, por sus siglas en inglés), es una tecnología que permite a las

computadoras identificar y convertir imágenes o documentos de texto impresos en texto digital editable. El objetivo principal del reconocimiento de caracteres es automatizar el proceso de extracción y análisis de texto a partir de imágenes o documentos escaneados.

Primero, se aplican diversas técnicas de procesamiento de imágenes para mejorar la calidad y la legibilidad de la imagen. Esto puede incluir la eliminación de ruido, la corrección de la inclinación o distorsiones, la normalización del contraste y el brillo, entre otros ajustes.

Después, se divide la imagen en regiones o segmentos, que se analizan para extraer sus características. Una vez que se han extraído las características, se utiliza un algoritmo de clasificación para asignar una etiqueta a cada segmento, es decir, determinar el carácter que representa (figura 3.2).

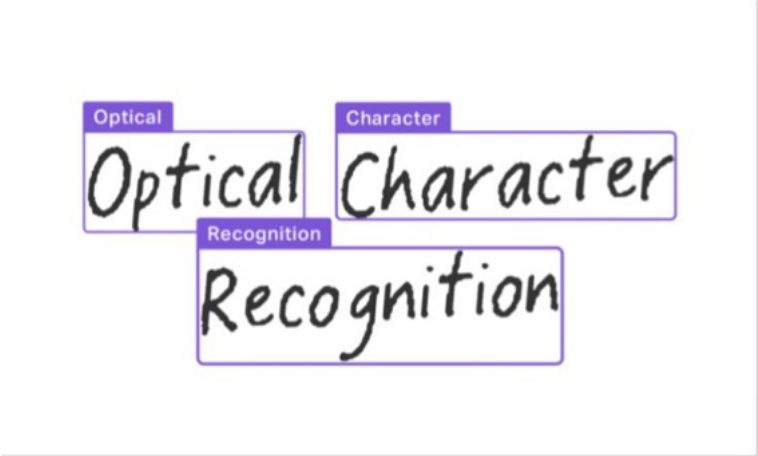

Figura 3.2: OCR

Fuente: Eden AI

En visión artificial, una imagen se representa como una matriz de píxeles. Cada píxel corresponde a un punto en la imagen y contiene información sobre su color o nivel de intensidad. La representación más común de una imagen es en escala de grises o en color RGB (Rojo, Verde, Azul), aunque también existen otros modelos de color como el HSV (Matiz, Saturación, Valor) o el CMYK (Cian, Magenta, Amarillo, Negro).

En una imagen en escala de grises, cada píxel se representa con un único valor de intensidad, que varía desde 0 (negro) hasta 255 (blanco), o bien 1 si se representa como decimales. Este valor indica cuán oscuro o claro es el píxel. En una imagen en color RGB, cada píxel se representa como una combinación de tres componentes: rojo, verde y azul. Cada componente tiene un valor que especifica la cantidad de cada color primario presente en el píxel. Este formato, pues, se representa mediante una matriz tridimensional donde la primera dimensión representa el ancho, la segunda el alto y la última los canales que componen los píxeles.

3.1.2. Aprendizaje automático

El aprendizaje automático, conocido en inglés como *machine learning*, es una rama de la inteligencia artificial que se centra en el desarrollo de algoritmos y modelos computacionales que permiten a las máquinas aprender y mejorar automáticamente a partir de los datos. En lugar de programar explícitamente todas las reglas y pasos necesarios para llevar a cabo una tarea, el aprendizaje automático permite que los sistemas informáticos aprendan de manera autónoma a través de la experiencia y los datos disponibles. Este tipo de algoritmos son utilizados especialmente cuando se dispone de una muestra grande de datos pero no de las reglas necesarias para llevar a cabo la tarea.

El aprendizaje automático se aplica en una amplia gama de campos y tareas, como reconocimiento de voz, procesamiento de imágenes, traducción automática, filtrado de spam, detección de fraudes, recomendación de productos, diagnóstico médico, conducción autónoma y muchos otros.

El proceso de *machine learning* involucra los siguientes pasos:

1. **Recopilación de datos**: Se reúnen datos relevantes y representativos para la tarea que se desea abordar. Estos datos pueden provenir de diversas fuentes, como bases de datos, archivos, sensores, registros en línea, entre otros.

2. **Preprocesado de datos**: Los datos recopilados pueden contener ruido, valores atípicos o estar incompletos, estar en un formato poco legible para el algoritmo, etc. Por ello, se realizan diversas técnicas de limpieza y transformación de datos para asegurar que estén en un formato adecuado para el análisis.

En ocasiones, el conjunto de datos puede estar desequilibrado, es decir, que la distribución de datos contenga muchos más datos de una categoría que de otra. Existen diversas técnicas para modificar la distribución de datos y equilibrarla: estas se pueden clasificar en *oversampling*, si crean muestras de datos sintéticas; o *undersampling*, en caso de descartar muestras de datos. También se suelen utilizar técnicas de *oversampling* o ampliación de datos en caso de disponer de muestras pequeñas: esto es común en conjuntos de datos de imágenes donde éstas pasan por filtros de edición de imágenes.

3. **Selección de características**: En ocasiones, los datos recopilados pueden contener una gran cantidad de características o variables. En este paso, se seleccionan las características más relevantes o se reduce la dimensionalidad de los datos para simplificar el problema y mejorar la eficiencia del modelo.

4. **Elección del algoritmo de aprendizaje**: Existen varios algoritmos y enfoques de aprendizaje automático, como árboles de decisión, redes neuronales, máquinas de vectores de soporte, entre otros. La elección del algoritmo depende del tipo de problema y de los datos disponibles.

5. **Entrenamiento del modelo**: El conjunto de datos se particiona en conjuntos de entrenamiento y de prueba. Durante el entrenamiento, el modelo utiliza el conjunto de entrenamiento para aprender patrones y relaciones en los datos para realizar predicciones o tomar decisiones, en base a una serie de parámetros que ajustan el comportamiento del algoritmo o *hiperparámetros*.

6. **Evaluación del modelo**: Una vez entrenado el modelo, se evalúa su rendimiento utilizando el conjunto de datos de prueba. Se analizan métricas como la precisión, el error o el desempeño general del modelo para determinar su eficacia.

7. **Ajuste y optimización**: Si el rendimiento del modelo no es satisfactorio, se realizan ajustes en los hiperparámetros o en el propio algoritmo para mejorar su desempeño. Este proceso se repite hasta alcanzar un modelo óptimo.

   Dicho proceso se puede realizar de forma manual o utilizando técnicas que entrenan una serie de modelos seleccionando los hiperparámentros dados unos rangos de valores para cada uno. La estructura de datos resultante y que

determina el modelo óptimo se conoce como *hipermodelo*.

Existen diversos tipos de algoritmos, pero fundamentalmente se clasifican en:

- **Aprendizaje supervisado**: los datos de entrenamiento están etiquetados con la respuesta deseada. El algoritmo aprende a predecir las etiquetas a través de las características de los datos. A su vez, se pueden clasificar en algoritmos de clasificación, si la etiqueta representa una categoría de un conjunto finito de ellas; o regresión, si la etiqueta es un valor de un rango continuo.

- **Aprendizaje no supervisado**: los datos de entrenamiento no están etiquetados. El algoritmo debe buscar patrones o relaciones en los datos. Dichos algoritmos abarcan los de agrupamiento o *clustering* y los de reducción de dimensiones.

- **Aprendizaje por refuerzo**: el algoritmo aprende a través de la interacción con un entorno, recibiendo recompensas o penalizaciones según sus acciones. A medida que el algoritmo explora el entorno, busca maximizar las recompensas a largo plazo.

3.1.3. Aprendizaje profundo

El aprendizaje profundo, también conocido como *deep learning*, es una rama del campo de la inteligencia artificial que se centra en el desarrollo y entrenamiento de modelos de redes neuronales artificiales. Estas redes neuronales están diseñadas para imitar el funcionamiento del cerebro humano y son capaces de aprender y extraer patrones complejos a partir de grandes conjuntos de datos.

Las redes neuronales se componen de múltiples capas de neuronas interconectadas. Cada neurona recibe una serie de valores de entrada y calcula una salida en base a una función conocida como *función de activación* y unos pesos para cada entrada que se van ajustando a lo largo del aprendizaje. Todas las redes neuronales constan de una capa de entrada, una capa de salida y un número variable de capas intermedias llamadas capas ocultas. Este modelo se esquematiza en la figura 3.3.

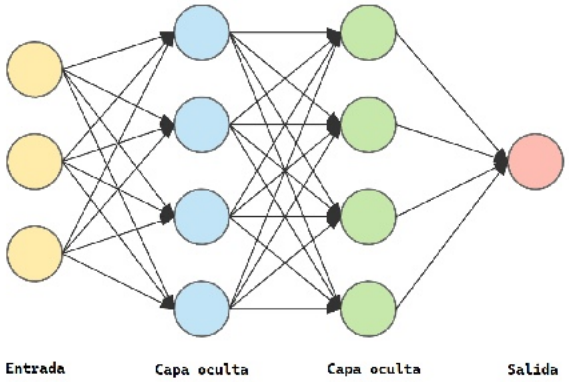

Figura 3.3: Estructura básica de una red neuronal

Fuente: Pablo Huet - OpenWebinars

Existen diferentes tipos de redes neuronales, según la distribución e interconexión de capas:

- **Redes Neuronales Secuenciales**: También conocidas como redes neuronales de propagación hacia adelante o *feedforward*, son el tipo más básico de redes neuronales. Están compuestas por una secuencia lineal de capas, donde las conexiones entre las neuronas no forman ciclos, y la información fluye en una dirección, desde la capa de entrada a través de las capas ocultas hasta la capa de salida. Principalmente están compuestas por capas totalmente conectadas, formadas por una fila de neuronas donde cada una está conectada con todas las de la capa anterior.

- **Redes Neuronales Convolucionales (CNN)**: Están especialmente diseñadas para el procesamiento de datos estructurados en forma de matrices, como imágenes. Las CNN utilizan capas convolucionales que aplican filtros a regiones locales de datos para extraer características importantes. También incluyen capas de submuestreo (*pooling*) para reducir la dimensionalidad y capas totalmente conectadas para realizar la clasificación final. Esto se puede ver en la figura 3.4

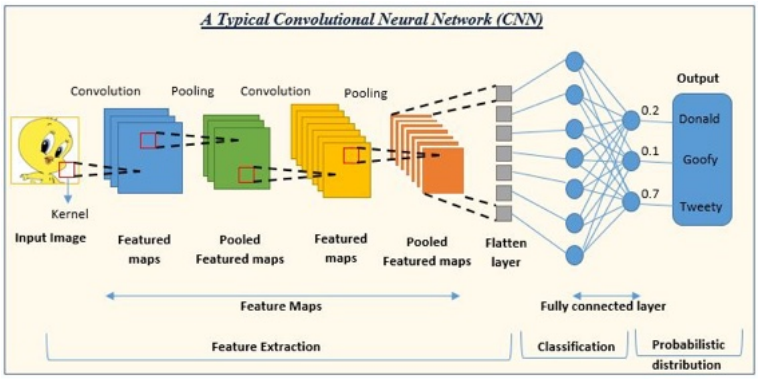

Figura 3.4: Ejemplo de red neuronal convolucional

Fuente: Saily Shah - Analytics Vidhya

- **Redes Neuronales Recurrentes (RNN)**: Estas redes están diseñadas para modelar datos secuenciales o de naturaleza temporal, como el lenguaje natural o la música. Las RNN utilizan conexiones retroalimentadas que permiten que la información se retroalimente a través de ciclos, lo que les da la capacidad de mantener la memoria de eventos pasados. Una variante popular de las RNN son las LSTM (redes neuronales de memoria a largo plazo), que abordan el problema de las dependencias a largo plazo.

- **Redes Neuronales Generativas Antagónicas (GAN)**: Consisten en dos redes neuronales: el generador y el discriminador. El generador crea datos sintéticos, mientras que el discriminador intenta distinguir entre los datos generados y los datos reales. Ambas redes se entrenan en un proceso de competencia mutua hasta que el generador es capaz de generar datos que son indistinguibles de los reales. Las GAN se utilizan en aplicaciones de generación de imágenes, síntesis de voz, entre otras.

  La figura 3.5 muestra el esquema de funcionamiento de una GAN.

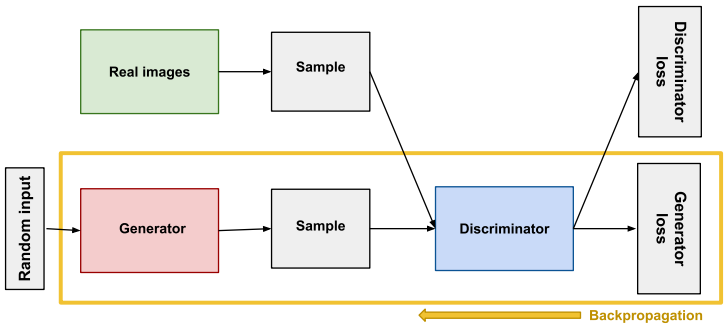

Figura 3.5: Estructura de una red neuronal generativa antagónica

Fuente: Google Developers

- **Redes Neuronales Recurrentes Encoder-Decoder (Seq2Seq)**: Estas redes se utilizan para el procesamiento de secuencias, donde una red neuronal recurrente actúa como codificador para capturar la información de la secuencia de entrada y otra red recurrente actúa como decodificador para generar una secuencia de salida. Se utilizan en tareas como la traducción automática, la generación de subtítulos de imágenes y el resumen de texto.

Uno de los fundamentos del aprendizaje profundo es el tensor, una estructura de datos multidimensional que consiste en una generalización de escalares, vectores y matrices a dimensiones superiores.

Conceptos clave:

- Orden o rango del tensor: Número de dimensiones que tiene. Un tensor de orden 0 es un escalar (un solo valor). Un tensor de orden 1 es un vector (una secuencia de valores). Un tensor de orden 2 es una matriz (una tabla bidimensional de valores). Un tensor de orden 3 es un cubo de valores (como una imagen, que consiste en varios canales formados por matrices), y así sucesivamente.

- Forma del tensor: La forma de un tensor se refiere al tamaño de cada una de sus dimensiones. Por ejemplo, un tensor de forma (3, 4) es una matriz con 3 filas y 4 columnas. Un tensor de forma (2, 3, 4) es un cubo con 2 filas, 3 columnas y 4 capas.

- Elementos del tensor: Los elementos de un tensor son los valores almacenados

en él. Por ejemplo, un tensor de forma (2, 2) puede contener los valores [1, 2, 3, 4]. Cada valor individual en el tensor se puede acceder mediante índices, que indican su posición en cada dimensión.

- Operaciones con tensores: Los tensores se pueden someter a varias operaciones matemáticas, como suma, resta, multiplicación y división elemento a elemento. Además, hay operaciones específicas para manipular la forma de los tensores, como la transposición, la concatenación y el redimensionamiento.

3.2. Tecnologías usadas

Como lenguaje de programación, se ha utilizado Python, ya que es un lenguaje versátil y muy utilizado en ciencia de datos, visión artificial y aprendizaje automático; con la distribución Anaconda, una distribución de Python que está diseñada específicamente para el análisis de datos y la ciencia de datos. Proporciona un entorno completo y listo para usar que incluye el intérprete de Python, así como una amplia colección de bibliotecas y herramientas populares utilizadas en el ámbito de la ciencia de datos.

La principal ventaja de Anaconda es que simplifica la configuración y gestión del entorno de desarrollo para proyectos de análisis de datos. Además de Python, Anaconda incluye el administrador de paquetes Conda, que facilita la instalación y actualización de paquetes y bibliotecas adicionales.

Las principales librerías de Python utilizadas en este proyecto son las siguientes:

- **NumPy**: es una biblioteca de Python que proporciona soporte para la manipulación de matrices y cálculos numéricos eficientes. Es una de las bibliotecas fundamentales en el ecosistema de ciencia de datos y aprendizaje automático de Python, y forma la base de muchas otras bibliotecas populares, como Pandas y scikit-learn.

  NumPy está escrita en C y es esencial en el desarrollo de aplicaciones científicas y de aprendizaje automático en Python. Se utiliza para la manipulación eficiente de datos, cálculos numéricos, modelado matemático, procesamiento de

señales, álgebra lineal, simulaciones y más. Además, al ser la base de muchas otras bibliotecas, NumPy proporciona la estructura fundamental para realizar operaciones numéricas de manera eficiente en todo el ecosistema de Python.

Se ha utilizado NumPy ya que es la base de Python para trabajar con matrices y otras librerías dependen de él.

- **OpenCV**: OpenCV (Open Source Computer Vision Library) es una biblioteca de código abierto ampliamente utilizada para el procesamiento de imágenes y la visión por computadora. Fue desarrollada originalmente por Intel en 1999 y, desde entonces, ha sido mantenida por una comunidad activa de desarrolladores.

  OpenCV está escrita en C++ y cuenta con interfaces para varios lenguajes de programación, incluyendo Python y Java. Proporciona más de 2500 algoritmos optimizados para el procesamiento de imágenes y la visión por computadora, que abarcan una amplia gama de tareas, como manipulación de imágenes, detección y seguimiento de objetos, reconocimiento facial, calibración de cámaras, entre otros.

  Se ha utilizado OpenCV ya que es una librería sencilla de utilizar y con una amplia gama de funciones.

- **Pillow**: Es una biblioteca de manipulación de imágenes de código abierto para el lenguaje de programación Python. Proporciona un conjunto de funciones y métodos que permiten cargar, manipular, guardar y procesar imágenes en varios formatos.

  Pillow es ampliamente utilizada en aplicaciones que requieren manipulación y procesamiento básico de imágenes, como aplicaciones web, automatización de tareas relacionadas con imágenes, generación de miniaturas, procesamiento por lotes y muchas otras áreas donde se necesita trabajar con imágenes en Python.

  Se ha utilizado Pillow para tareas específicas que OpenCV no abarca, como algunos filtros o texto con transparencia y fuente personalizada.

- **TensorFlow**: TensorFlow es una biblioteca de código abierto desarrollada por Google que se utiliza ampliamente para realizar tareas de aprendizaje automático

y creación de modelos de inteligencia artificial. Proporciona un marco flexible y eficiente para construir y entrenar redes neuronales, así como para realizar cálculos numéricos de alto rendimiento en grandes conjuntos de datos.

Se ha utilizado TensorFlow al ser una de las librerías más intuitivas de utilizar para desarollar redes neuronales y soporta aceleración por GPU.

- **scikit-learn**: Es una biblioteca de aprendizaje automático de código abierto para Python. Proporciona una amplia gama de algoritmos y herramientas para tareas de aprendizaje supervisado y no supervisado, así como para la validación de modelos, selección de características, preprocesamiento de datos y evaluación de rendimiento.

  scikit-learn se utiliza ampliamente en la comunidad de ciencia de datos y aprendizaje automático debido a su facilidad de uso, su amplia selección de algoritmos y su enfoque en la consistencia y la calidad de la implementación. Es una herramienta valiosa tanto para principiantes como para expertos en aprendizaje automático que desean desarrollar modelos de forma rápida y eficiente.

3.3. Trabajos relacionados

A continuación se resumen algunos de los estudios encontrados relacionados con los temas de este trabajo.

3.3.1. Digital Image Watermarking for Photo Authentication in Thai national ID card

El artículo propone un método para insertar una marca de agua en la fotografía personal de un documento de identidad [2].

Dado que los rasgos físicos de una persona cambian a lo largo del tiempo, en este proceso se inserta un código que identifica a la persona en su foto de DNI. Para verificar la autenticidad de la imagen, se puede revertir el proceso y extraer la marca de agua incrustada (figura 3.6).

Figura 3.6: Esquema de funcionamiento de la marca de agua

Fuente: [2]

3.3.2. Pixel-wise supervision for presentation attack detection on identity document cards

El artículo se centra en la supervisión a nivel de píxel de imágenes de documentos de identidad para diferenciar los documentos legítimos de los reproducidos digitalmente o por impresora [3].

Para ello, los autores proponen una red neuronal basada en DenseNet, una arquitectura de red neuronal donde todas las capas están conectadas entre sí, a fin de evitar que el número de parámetros y de características aumente excesivamente e incluso que se diluya la información relevante sobre la imagen. El modelo propuesto utiliza dos bloques de DenseNet y una capa densa para obtener la salida. Pero, además, tras el segundo bloque, se ha añadido una capa convolucional con un kernel de 1x1 para el análisis de la imagen píxel a píxel.

La arquitectura de la red se resume en la figura 3.7.

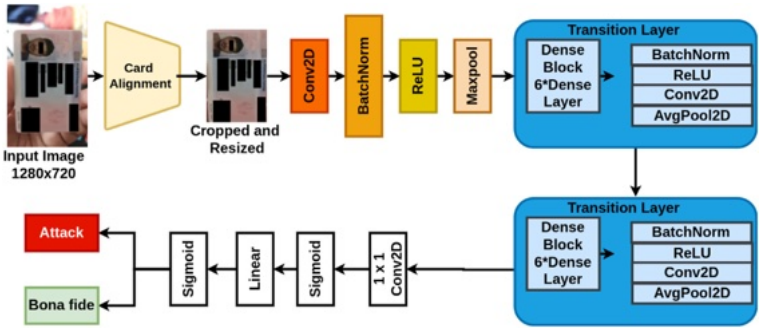

Figura 3.7: Estructura del modelo

Fuente: [3]

El entrenamiento se ha realizado con un conjunto de datos privado con 433 vídeos. El modelo se entrena durante 10 épocas con técnicas de parada temprana para evitar el *overfitting*.

El modelo alcanza una tasa de error equivalente (EER) del 3,24 % y una BPCER del 2,64 % y 2,09 % con unas APCER del 5 % y 10 %

3.3.3. Towards Efficient and Scale-Robust Ultra-High-Definition Image Demoiréing

Este proyecto se centra en la eliminación en imágenes de un efecto conocido como moiré, que se produce al fotografiar una imagen a través de una pantalla, que consiste en una capa de ruido formada por franjas o mallas de colores [4]. No está enfocada a documentos de identidad, sino a la eliminación de ruido en imágenes en general. En la figura 3.8 se puede ver un ejemplo de funcionamiento.

Figura 3.8: Ejemplo de foto antes y después del filtro

Fuente: [4]

3.3.4. Synthetic ID Card Image Generation for Improving Presentation Attack Detection

En este artículo se exponen una serie de métodos para generar documentos de identidad sintéticos con el fin de probar y mejorar los algoritmos de detecciones de ataques [5]. El artículo se basa en documentos de identidad chilenos y utiliza un conjunto de datos con cuatro clases:

- *Bona fide*: extractos de documentos de identidad legítimos.
- *Composite*: documentos de identidad legítimos cuyos campos o fotos han sido modificados manual o informáticamente.
- *Print*: documentos de identidad impresos en papel satinado.
- *Screen*: documentos de identidad mostrados a través de una pantalla y fotografiados con un segundo dispositivo.

Para generar muestras, se han utilizado GAN que generan nuevas imágenes o añaden ruido a las ya existentes. Ejemplos de resultado en la figura 3.9. Para clasificar y evaluar el impacto de los ataques, se han implementado varios modelos basados en MobileNetV2, comparando el rendimiento de entrenamiento usando solamente imágenes legítimas y el conjunto de datos al completo.

Figura 3.9: Ejemplos de DNI generados artificialmente

Fuente: [5]

El artículo presenta varios métodos para generar documentos de identidad sintéticos:

- Generación a través de técnicas de edición de imagen y una plantilla de documento de identidad.
- Generación de imágenes falsas a través de transferencia de texturas a imágenes *bona fide*.
- Generación de documentos de identidad sintéticos a través de redes generativas antagónicas.

En cuanto a los resultados, se expresan en las métricas APCER (falsos negativos) y BPCER (falsos positivos). Con el conjunto de datos entero, logra una EER del 6,18 % y un BPCER del 3,42 % con un APCER del 10 %.

3.3.5. Face Image Quality Vector Assessment for Biometrics Applications

El artículo desarrolla un modelo de medida de calidad de imágenes dedicadas a biometría [6]. Por ejemplo, un modelo de este tipo permite medir cuán apropiada es una imagen para reconocimiento facial o para ser usada en documentos oficiales, descartando las imágenes que no cumplan unos estándares mínimos de calidad.

Para ello, han confeccionado una red neuronal convolucional multitarea, basada en ResNet-50. El equipo ha sustituido la capa final de regresión por tres capas densas, de dimensiones de salida 2048, 256 y 64 filtros, respectivamente. Acto seguido, la red se divide en cuatro ramas, cada una dedicada a una tarea y con tres capas independientes,

como se puede ver en la figura 3.10.

- La primera rama está dedicada al estimador de calidad, con tres capas totalmente conectadas de 32 neuronas y una capa de regresión.
- La segunda rama es un estimador de poses. Se compone de dos capas totalmente conectada de 32 y 16 neuronas (respectivamente) y una capa de clasificación de 5, dado que el sistema clasifica entre 5 poses diferentes.
- La tercera rama clasifica la expresión en dos clases: neutral y no neutral.
- La cuarta rama analiza la iluminación de la imagen y la clasifica en tres clases: sobreexpuesta, bien expuesta y subexpuesta.

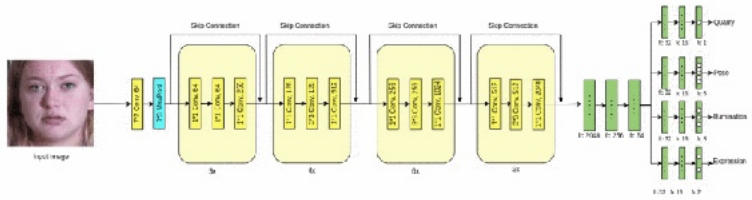

Figura 3.10: Arquitectura de la red neuronal multitarea

Fuente: [6]

El equipo ha utilizado el conjunto de datos CMU Multi-PIE, con más de 750 000 imágenes de 337 sujetos realizas en sesiones a lo largo de 5 meses, bajo 19 condiciones de iluminación y 15 puntos de vista, así como diferentes expresiones faciales.

Para mejorar el rendimiento del modelo con imágenes de baja calidad, y debido a que este tiene más de 200 millones de parámetros entrenables, el equipo ha utilizado técnicas de aumento de datos: ruido gaussiano, reescalado, desenfoque gaussiano, etc.

Para etiquetar las imágenes, se han basado en los criterios de ISO/IEC 19794-5.

El modelo obtiene los siguientes resultados: precisión del 92,71 % para la estimación de poses, 93,15 % para las expresiones faciales y 87,35 % para la iluminación.

3.3.6. A masked-face detection algorithm based on M-EIOU loss and improved ConvNeXt

El artículo presenta un modelo de detección de oclusión de una cara basado en YOLOX y en ConvNeXt[7].

El modelo utiliza técnicas tales como convoluciónes por profundidad, cuello de botella inverso (módulo con dos extremos estrechos y un medio ancho), la función de activación GELU en vez de ReLU, etc.

Como conjunto de datos ha utilizado VOC y AIZOO, usando además aumento de datos por mosaico, técnica que consiste en juntar cuatro imágenes en una, escalándolas y volteándolas.

El modelo logra una precisión mayor que otros, llegando al 71,9 %.

3.3.7. Desarrollo de un aplicativo móvil para la extracción automática de información del documento de identificación mediante visión computacional

El artículo propone un algoritmo para la segmentación y lectura de datos personales de documentos de identidad peruanos [8].

Como primer paso, utiliza OpenCV para el preprocesado y segmentación de los datos: utilizando umbralización, `morphologyEx` en modo «opening» y detección de palabras y letras calculando histogramas columna a columna.

Para la lectura de los caracteres, los autores proponen dos modelos: Adaboost, que es más ligero; y YOLO v3 tiny, un modelo convolucional que es una versión reducida de la tercera versión del modelo YOLO.

Para el primero prepara una serie de muestras a partir de los DNI. El modelo se basa en los descriptores de Haar, una serie de características obtenidas al aplicar filtros en horizontal o vertical a la imagen base; y, a partir de dichos descriptores, clasifica la letra.

Para el segundo entrena la red neuronal partiendo de cierta configuración de

pesos inicial.

Los modelos Adaboost y YOLO v3 tiny calsifican correctamente los datos en un 88,52 % y 99,87 %, respectivamente para cada datos.

Capítulo 4

Material y Método

Con el fin de de desarrollar y cumplir los objetivos marcados en el capítulo anterior, se han seguido una serie de métodos que se describen a continuación en este capítulo. Dichos métodos consisten en una serie de algoritmos que cumplen un objetivo concreto. El material consiste en un entorno de Anaconda con las librerías necesarias para su funcionamiento y uno o más conjuntos de datos dependiendo del fin de dicho método, como se resume en la tabla 4.1.

Conjunto de datos	Descripción	Secciones
Conjunto propietario de vídeos de DNI	Vídeos de DNI enseñando el kinegrama	4.1, 4.2
Conjunto propietario de fotos de DNI con moiré	Imágenes de DNI con o sin moiré	4.4
Conjunto sintético de fotos de DNI (véase 4.7)	Resultados de generación de DNI para clasificación de tipo de DNI	4.3
Face Dataset Of People That Don't Exist [9]	Fotos sintéticas de personas	4.5, 4.7
100k Faces [10]	Fotos sintéticas de personas	4.5, 4.7
Glasses or no glasses [11]	Fotos sintéticas de personas con o sin gafas	4.6

Tabla 4.1: Conjuntos de datos utilizados

A la hora de confeccionar los algoritmos que se describen en este capítulo, se han utilizado los equipos descritos en la tabla 4.2:

SO	CPU	RAM	GPU	Almacenamiento
Windows 11	Intel Core i7-11700KF	32 GB DDR4-3200	Nvidia GeForce RTX 3070	NVMe PCIe 3.0
Windows 10	Intel Core i7-7700K	32 GB DDR4-3600	Nvidia GeForce RTX 2060	NVMe PCIe 3.0 SATA SSD / HDD

Tabla 4.2: Características de los equipos utilizados

Para medir la exactitud de los modelos de predicción, las métricas más utilizadas son las que se muestran en la tabla 4.3:

Nombre	Explicación	Fórmula
TP	Verdadero positivo, positivo predicho como tal	
TN	Verdadero negativo, negativo predicho como tal	
FP	Falso positivo, negativo predicho como positivo	
FN	Falso negativo, positivo predicho como negativo	
Pérdida	Medida en que las predicciones del modelo distan de las reales, sirve para entrenar el modelo	
Accuracy	Tasa de acierto del modelo	$\frac{TP+TN}{TP+TN+FP+FN}$
Precision	Medida en la que los positivos detectados son verdaderos	$\frac{TP}{TP+FP}$
Recall	Medida en la que se detectan los positivos	$\frac{TP}{TP+FN}$
F1 score	Rendimiento combinado	$2 \cdot \frac{precision \cdot recall}{precision+recall}$
Matriz de confusión	Representación de clases predichas vs. clases reales	

Tabla 4.3: Métricas utilizadas para la evaluación de clasificadores

En caso de clasificación multiclase, las métricas se calculan para cada clase con el resto: los positivos se refieren a la categoría y los negativos al resto. Después, se puede calcular la media entre las métricas de todas las clases.

4.1. Detección de kinegrama

El kinegrama se encuentra grabado en el documento de identidad. Para demostrar su veracidad, el usuario debe enseñar un vídeo del DNI, moviéndolo para que la imagen visible del kinegrama cambie.

En primer lugar, es necesario un algoritmo que detecte el kinegrama en una imagen. Para ello, el mejor método es una red neuronal convolucional pensada para detectar patrones.

El algoritmo detectará el kinegrama fotograma a fotograma, para detectar si existe kinegrama y, además, con qué frecuencia aparece. Esto se debe a que no es siempre visible y, aunque es necesario que aparezca para demostrar su autenticidad, no debe aparecer siempre, ya que no está construido de esa forma; de lo contrario, el documento sería sospechoso de ser falsificado.

El proceso es el siguiente: un modelo entrenado detecta el kinegrama a lo largo del vídeo, generando una distribución de aparición del kinegrama. Otro algoritmo la analiza y determina si el documento es verdadero o falso. Un documento puede ser falso bien porque no tiene kinegrama grabado, o bien porque tiene un símbolo detectado como kinegrama pero no funciona de manera precisa haciendo que se mantenga visible.

Para ello, se toma la precisión con la que se detecta el kinegrama en cada fotograma y dichos datos se usan como entrada de una red neuronal lineal, que determina si el documento es verdadero o falso.

4.2. Reconocimiento de texto

Se propone utilizar OCR para leer los datos del documento de identidad. Esto se puede utilizar para comprobar si son legibles, validarlos o cotejarlos con los datos introducidos por el usuario.

Pare ello, el algoritmo utiliza la API OCR de Tesseract para leer cada uno de los campos del DNI. Tesseract-OCR es un motor de reconocimiento óptico de caracteres de código abierto ampliamente utilizado, desarrollado originalmente por Hewlett-Packard Labs y actualmente mantenido por el grupo de desarrollo de Google.

Primero, se identifica el tipo de documento que es. Después, se recorta la imagen en los campos correspondientes: conocer el tipo de documento permite realizar los recortes de manera precisa. A continuación, el OCR lee los recortes de los campos para obtener el texto correspondiente a dicho campo; para ello, se ha utilizado paralelismo a nivel de hilo para mejorar el rendimiento. La API de OCR está configurada para leer los datos como líneas separadas y solo los caracteres imprescindibles para cada uno de los campos.

En la figura 4.1 se puede ver un ejemplo de funcionamiento donde el algoritmo segmenta los campos y obtiene el texto representado en ellos.

Figura 4.1: Ejemplo de reconocimiento de texto

Los resultados obtenidos se anotan en una tabla que realiza el recuento de datos obtenidos. Cuando termina de procesar el vídeo, el algoritmo selecciona los datos con un recuento mayor. Solo se toman los resultados que cumplan con una expresión regular dada para cada campo, que determina las cadenas que son válidas.

Algoritmo 1 Lectura de datos en vídeo

1: $tipo \leftarrow obtener_tipo_dni(video)$
2: **para todo** $fgrama\ en\ video$ **hacer**
3: **para todo** $campo\ en\ campos$ **hacer**
4: $recorte \leftarrow recortar(fgrama, campo)$
5: $dato \leftarrow ocr(recorte)$
6: $resultados[campo].añadir(dato)$
7: **fin para**
8: **fin para**
9: **para todo** $campo\ en\ campos$ **hacer**
10: $mejores[campo] \leftarrow mejor(resultados[campo])$
11: **fin para**
devolver $mejores$

4.3. Identificación de tipo de DNI

Identificar de qué versión de DNI se trata permite conocer un rasgo importante del propio documento y además permite ejecutar algunos algoritmos con más precisión, como el OCR.

Para ello, se ha utilizado una red neuronal convolucional que toma como entrada el DNI con un tamaño normalizado y obtiene la clase a la que pertenece (DNI 3.0, DNI 4.0, etc.).

La red neuronal consiste en tres capas convolucionales de 16, 32 y 64 filtros, respectivamente; cada una con un tamaño de kernel de 3x3, función de activación ReLU y tras cada una se enceuntra una capa de reducción de dimensionalidad por MaxPooling; una capa de aplanamiento y una capa totalmente conectada de 128 unidades. La capa de salida es una con una neurona por clase y función de activación *softmax*, que devuelve la probabilidad de que la entrada sea de cada una de sus clases. Dicha arquitectura se puede ver en la figura 4.2.

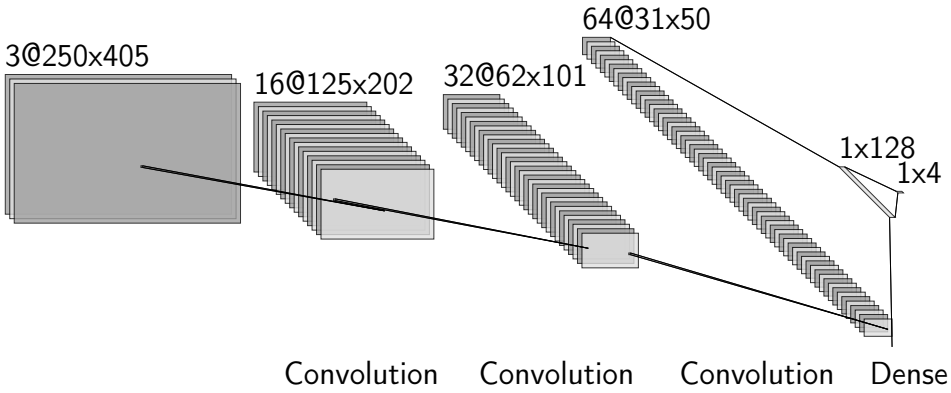

Figura 4.2: Estructura de la red neuronal utilizada

Se dispone de un conjunto de datos formado por DNI 3.0 y 4.0, tanto por delante como por detrás el conjunto tiene un total de 4000 imágenes sintéticas, 1000 por cada clase (ejemplos en la figura 4.3).

Figura 4.3: Ejemplos de DNI y sus tipos

4.4. Detección de moiré

El efecto moiré es un fenómeno visual que se manifiesta como un patrón de colores o distorsión de formas geométricas en las imágenes fotográficas. Se produce cuando se fotografían pantallas u objetos que presentan patrones geométricos de líneas, lo que da lugar a una interferencia que distorsiona la imagen resultante. Esto es lo que ocurre con la figura 4.4.

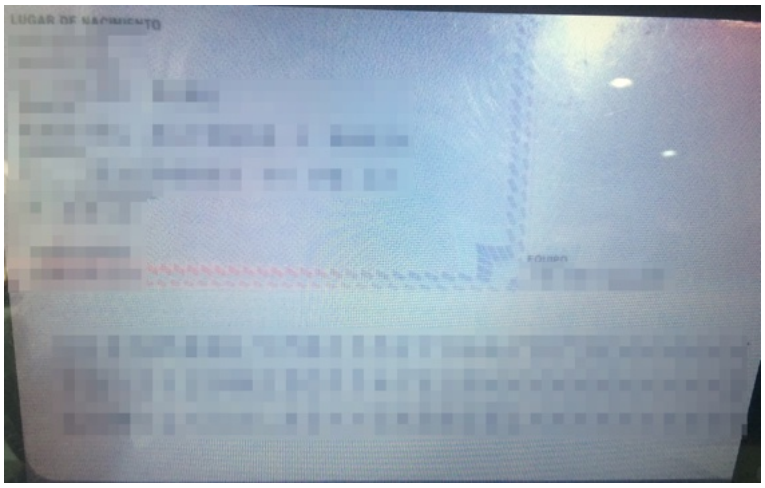

Figura 4.4: Ejemplo de DNI con moiré

Este efecto no solo puede ser apreciado en fotografías, sino que también desempeña un papel importante en la detección de documentos de identidad sospechosos de manipulación. Para lograr esto, se ha desarrollado un enfoque que utiliza un modelo preentrenado y probado para eliminar el moiré de una imagen capturada. Esta técnica implica aplicar un filtro especial que corrige las distorsiones generadas por el efecto moiré.

Una vez que se ha eliminado el moiré de la imagen original, se procede a medir la diferencia entre la imagen de entrada y la imagen filtrada. Para ello, se han utilizado diversas métricas (implementadas mediante la librería Sewar[12]) que realizan una estimación de cuánto ha cambiado la imagen al pasar por el filtro. Estos datos sobre las diferencias entre las imágenes son fundamentales para el siguiente paso del proceso de detección.

Para determinar si la imagen original tenía presencia de moiré o no, se emplea un clasificador especializado. Este clasificador analiza los datos recopilados previamente sobre las diferencias entre las imágenes y determina si la imagen original mostraba el patrón de moiré.

Algoritmo 2 Algoritmo de detección de imagen

1: $imagen_procesada \leftarrow demoire(imagen)$
2: **para todo** $metrica\ en\ metricas$ **hacer**
3: $\quad resultados[metrica] \leftarrow calcular_metrica(imagen, imagen_procesada, metrica)$
4: **fin para**
$tiene_moire \leftarrow analizar_metricas(resultados)$
devolver $tiene_moire$

Como clasificador se ha utilizado un hipermodelo de entre varios algoritmos para comparar cuál es el mejor algoritmo, con los hiperparámetros de la tabla 4.4; y utilizando las cinco métricas más relevantes seleccionadas mediante el método *KBest*, que selecciona las características más relevantes en base a una métrica dada que mide la correlación entre las características y las etiquetas. La implementación del clasificador se ha hecho utilizando la librería scikit-learn.

Algoritmo	Hiperparámetros
Random Forest	$max_depth" : \{5, 10, 15, None\}$ $"n_estimators" : \{75, 100, 250\}$
SVM	$"kernel" : \{"linear", "poly", "rbf"\}$ $"C" : \{10^i, i \in \{-4, -3, ..., 1\}\}$
KNN	$"n_neighbors" : 3, 5, ..., 13$ $"weights" : \{"uniform", "distance"\}$

Tabla 4.4: Resultados del entrenamiento para detección de moiré

Como conjunto de datos se han utilizado 332 imágenes de las cuales 181 están limpias y 151 contienen moiré. El conjunto de datos ha sido proporcionado por Mobbeel y es confidencial.

4.5. Estimación de calidad de imágenes de personas

Para mejorar la calidad de los DNI sintéticos, se ha procedido a seleccionar las imágenes más apropiadas para documentos de identidad. Dado que no existen conjuntos de datos específicos para carnet, se ha procedido a aplicar unos estándares de calidad a conjuntos de datos de imágenes existentes (véase anexo: Estándares de fotografías para carnet).

Para ello, se han aplicado una serie de algoritmos para medir las características de la imagen tales como la rotación de la cara o la luminosidad, y, a partir de dichos resultados, se asigna un puntaje de 0 a 100 según su calidad: cuanto mayor sea la puntuación, mejor calidad tendrá y más apropiada será para ser utilizada en un DNI.

Las técnicas utilizadas son las siguientes:

- Rotación de la cabeza: se ha utilizado un modelo que obtiene los puntos clave de la cara y, a partir de dichos datos, se ha utilizado un algoritmo que estima los tres ángulos de rotación de la cabeza (véase figura 4.5).

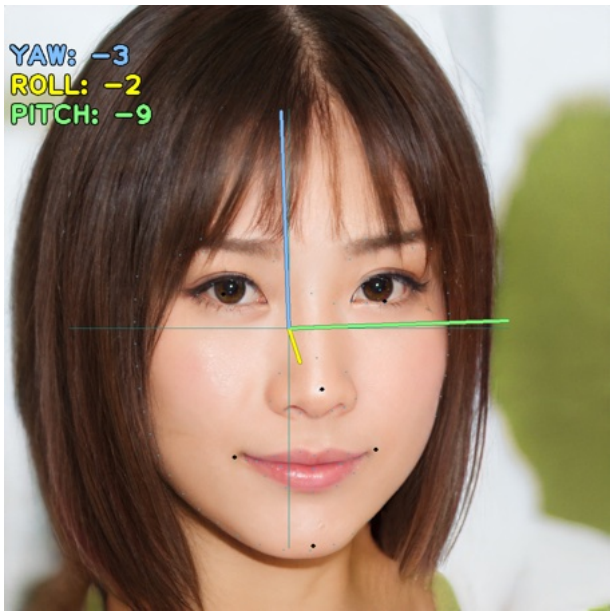

Figura 4.5: Ejemplo de cálculo de rotación de una cara

- Apertura de los ojos: se ha estimado a partir de los puntos clave mencionados anteriormente. La apertura aproximada absoluta se obtiene como la distancia entre el punto superior del ojo y el punto inferior. Para normalizarla a las dimensiones de la cara, se obtiene la distancia relativa, dividiéndola entre la distancia entre los ojos (véase figura 4.6).

- Apertura de la boca: al igual que con la apertura de los ojos, la apertura de la boca se estima a partir de los puntos de la cara. La distancia se define como la que separa el punto inferior del labio superior del punto superior del labio inferior (véase figura 4.6).

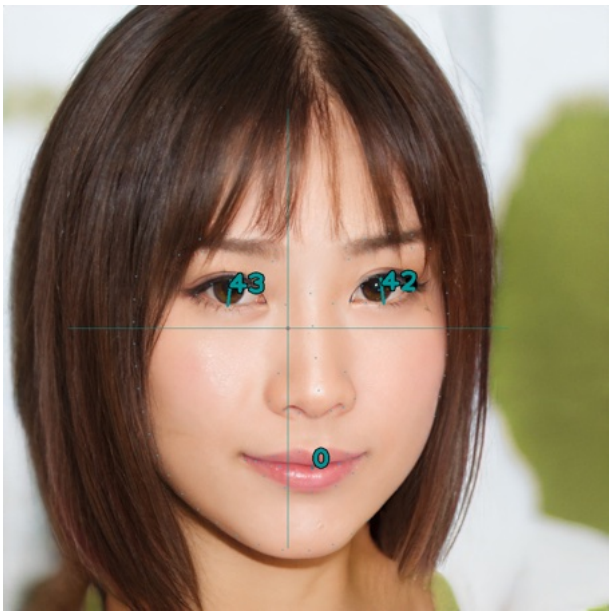

Figura 4.6: Ejemplo de cálculo de apertura de ojos y boca

- Exposición: primero, se ha obtenido el histograma de la imagen. A continuación, se obtiene el pico y la media del histograma.
- Nitidez: media de la imagen después de realizar una detección de bordes. Cuanto más nítida sea la imagen, mayor será el valor.
- Distancia de los ojos a los bordes: se definen como las distancias del ojo más cercano a los bordes derecho e izquierdo de la imagen, y del punto medio entre los ojos a los bordes superior e inferior (véase figura 4.7).

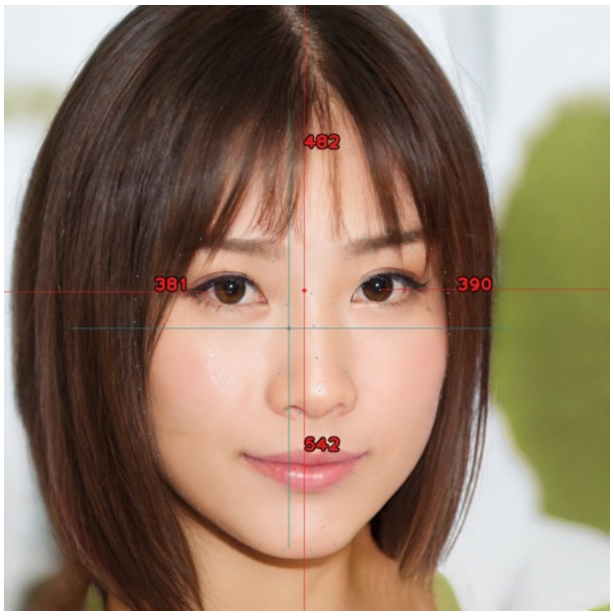

Figura 4.7: Ejemplo de cálculo de distancia de ojos a bordes

- Gafas: una red neuronal estima si una persona tiene o no gafas y si, de tenerlas, son gafas de sol.

Cada métrica se convierte a una puntuación de 0 a 100 que determina cuán favorable es, y dichas puntuaciones se convierten a una puntuación final.

La puntación se calcula como la media ponderada de la puntuación de cada una de las métricas; si una persona tiene gafas de sol, la puntuación se reduce a la mitad; si no se detecta exactamente una cara, la imagen se desecha.

4.6. Gafas

Como se ha mencionado anteriormente, se ha desarrollado un modelo que permite detectar si la imagen de una persona tiene gafas o no. El modelo está basado en MobileNetV2 con los pesos de ImageNet.

El conjunto de datos utilizado es el dataset «Glasses or no glasses» [11], con 5000 imágenes de personas sin gafas, con gafas de ver y gafas de sol. Se han clasificado en tres clases, con 2219 muestras sin gafas, 2553 muestras con gafas de ver y 228 muestras con gafas de sol. Ejemplos en la figura 4.8.

Figura 4.8: Muestras del conjunto de datos

4.7. Generación de DNI sintéticos

Se ha creado un programa para generar rápidamente imágenes sintéticas de DNI. El procedimiento consiste en aplicar técnicas de visión artificial a una imagen que sirva de plantilla, añadiendo una foto aleatoria y los datos pertinentes, generados aleatoriamente, pero coherentes.

Para ello, se han utilizado una serie de algoritmos:

- Primero, se genera una imagen y una serie de datos. Las fotos se obtienen mediante una base de datos de caras generadas mediante GAN, datos como nombre o apellidos se obtienen eligiendo una opción aleatoria de una base de datos, y otros como el número de DNI se generan aleatoriamente.
    - Foto: generada por inteligencia artificial.
    - Nombre: elección aleatoria de lista de nombres registrados en España [13].
    - Apellido: dos elecciones aleatoria de lista de apellidos registrados en España

[13].

- DNI, CAN, número de soporte y equipo de expedición: aleatorios según el formato adecuado. Sus formatos, así como de otros que siguen formatos estándar, son los que se muestran en la tabla 4.5:

Campo	Formato
DNI	8 cifras más 1 letra de control (véase Anexo A Características del DNI)
CAN	6 dígitos
Número de soporte	3 letras + 6 dígitos
Equipo de expedición	9 caracteres alfanuméricos
Sexo	«M»asculino o «F»emenino
Nacionalidad	ISO 3166-1-alfa-3 (a 3 letras) Ej: «ESP» para España [14]
Fecha de nacimiento Fecha de expedición Fecha de validez	Formato «DD MM YYYY»

Tabla 4.5: Formatos de los campos que siguen un formato concreto

- Nacionalidad: española por defecto.

- Sexo y fecha de nacimiento: determinados a partir de la foto elegida mediante un modelo de inteligencia artificial externo que estima la edad y género de una persona [15]. Nótese que pueden no ser acertados, se trata de obtener datos sintéticos.

  En caso de no disponer de foto, se generan aleatoriamente.

- Fecha de expedición y de validez: a partir de la fecha actual. La validez es de 5 años para menores de 30, 10 años hasta los 70 años y permanente a partir de los 70.

- Lugar de nacimiento: elección aleatoria de una lista de poblaciones [16] y sus provincias [17].
- Domicilio: elección aleatoria de una lista de poblaciones [16] y sus provincias [17], y de una lista de vías de Madrid [18] añadiendo un número aleatorio.
- Padres: dos elecciones aleatorias de la lista de nombres.
- MRZ: obtenido uniendo los datos anteriores. Para generar el bloque MRZ con los dígitos de control adecuados, se ha utilizado una librería externa [19]. El MRZ sigue el estándar ICAO 9303 referente a los documentos de viaje de tipo 1 [20] (el número de soporte corresponde al número de documento y el número de DNI se incluye en los datos opcionales de la primera fila), como se muestra en la figura 4.9:

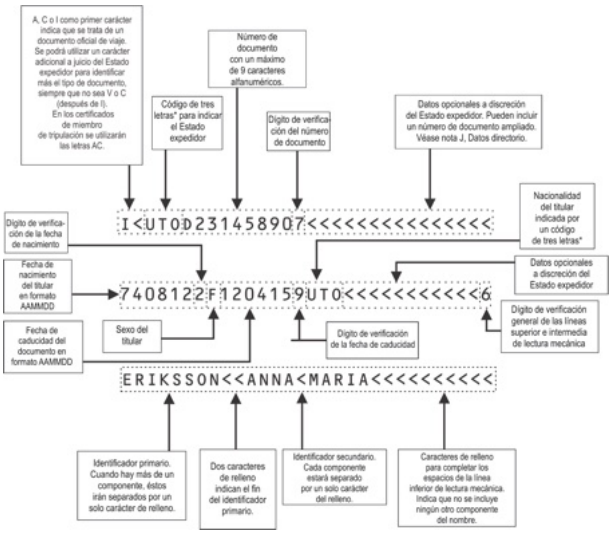

Figura 4.9: MRZ de los documentos de viaje 1

Fuente: [20]

- Se introducen los datos correspondientes en la plantilla, usando la fuente OCR-B [21] y aplicando algo de difuminado y transparencia para imitar el aspecto del DNI: opacidad del 75 % con un borde del 25 % para texto mediano, opacidad del 95 % con un borde del 75 % para texto grande, y un leve filtro de desenfoque.
- Se introduce la foto eliminando el fondo, cambiándola a escala de grises y

aplicando algunos ajustes de brillo y contraste. En concreto, la imagen se pega con una opacidad del 80 % y ajustando la luminosidad de la imagen utilizando ajuste de niveles. También se recorta ligeramente la imagen para adecuarla al formato carnet, procurando centrar la cara. Ejemplo en la figura 4.10

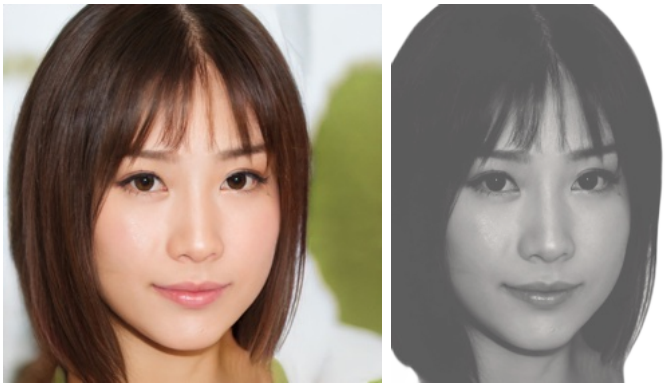

Figura 4.10: Foto antes y después de los filtros

- En el caso de la foto del bajorrelieve, la imagen ve reducida su opacidad hasta el 30 %, pero con mayor luminosidad en las columnas alternas, para imitar el efecto bajorrelieve, como se puede ver en la figura 4.11.

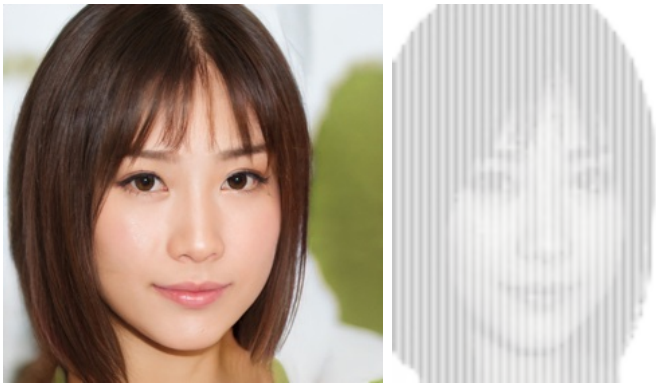

Figura 4.11: Foto antes y después de los filtros

- Se genera una firma utilizando la fuente PWSignatureTwo [22]. Dicha fuente está compuesta por letras que recuerdan a la caligrafía de firma y una serie de trazos especiales ubicados en los dígitos del 0 al 7. El algoritmo elige el primer nombre, el primer apellido y uno o más dígitos al azar y usa esa cadena con la fuente dada.

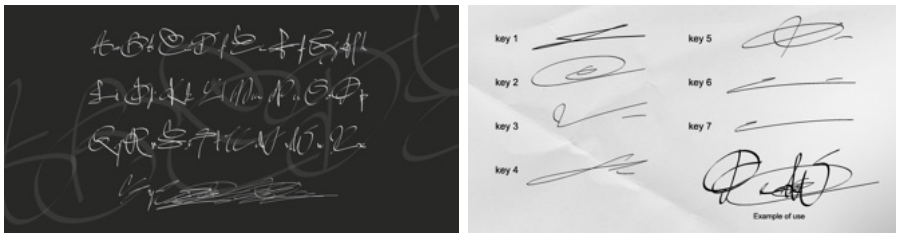

Figura 4.12: Trazos especiales de la fuente

Fuente: [22]

- Se añade ruido a la imagen: se modifica el tono, saturación, contraste y nitidez de la imagen en un −16 % a 16 %; se aplica un filtro de mediana de 3x3 y se inserta un ruido gaussiano con una desviación típica al azar comprendida entre 0 y 7. El resultado antes y después de los filtros se puede ver en la figura 4.13.

Figura 4.13: Foto antes y después de los filtros

Las fotos se eligen aleatoriamente de dos conjuntos de datos de imágenes de personas generadas por ordenador: *Face Dataset Of People That Don't Exist* [9] y *100k Faces* [10], que suman un total de 16 865 imágenes. Las imágenes escogidas son las más apropiadas de entre el total de imágenes utilizando una serie de métricas, como se describe en el apartado Estimación de calidad de imágenes de personas.

Figura 4.14: Ejemplos de muestras del conjunto de datos

Fuente: [9]

Capítulo 5

Resultados y discusión

Para probar el correcto funcionamiento de los algoritmos desarrollados, se han realizado una serie de pruebas, como se describe en este capítulo. Para los clasificadores (como el detector de tipo de DNI) se han realizado las pruebas sobre los conjuntos de datos dados y se han obtenido métricas que miden su eficacia. Para los que no pueden ser cotejados directamente por falta de datos de prueba (como el analizador de imágenes o generador de DNI), simplemente se muestran algunos ejemplos.

5.1. Detección de kinegrama

Se ha ejecutado el algoritmo y se ha guardado la certeza con la que el algoritmo detecta que el kinegrama está presente. La figura 5.1 muestra un ejemplo de detección en un fotograma concreto: el marco contiene la parte del documento donde el modelo ha detectado kinegrama y con qué certeza.

Figura 5.1: Ejemplo de detección de kinegrama

Se puede ver en la figura 5.2 las predicciones de si hay kinegrama a lo largo del análisis de un vídeo+, siendo el eje x cada uno de los fotogramas y el eje y la certeza. A más certeza, más probable es según el modelo de que haya kinegrama: por ejemplo: si es del 90 %, el algoritmo estima que hay un kinegrama en el área predicha con un 90 % de probabilidad.

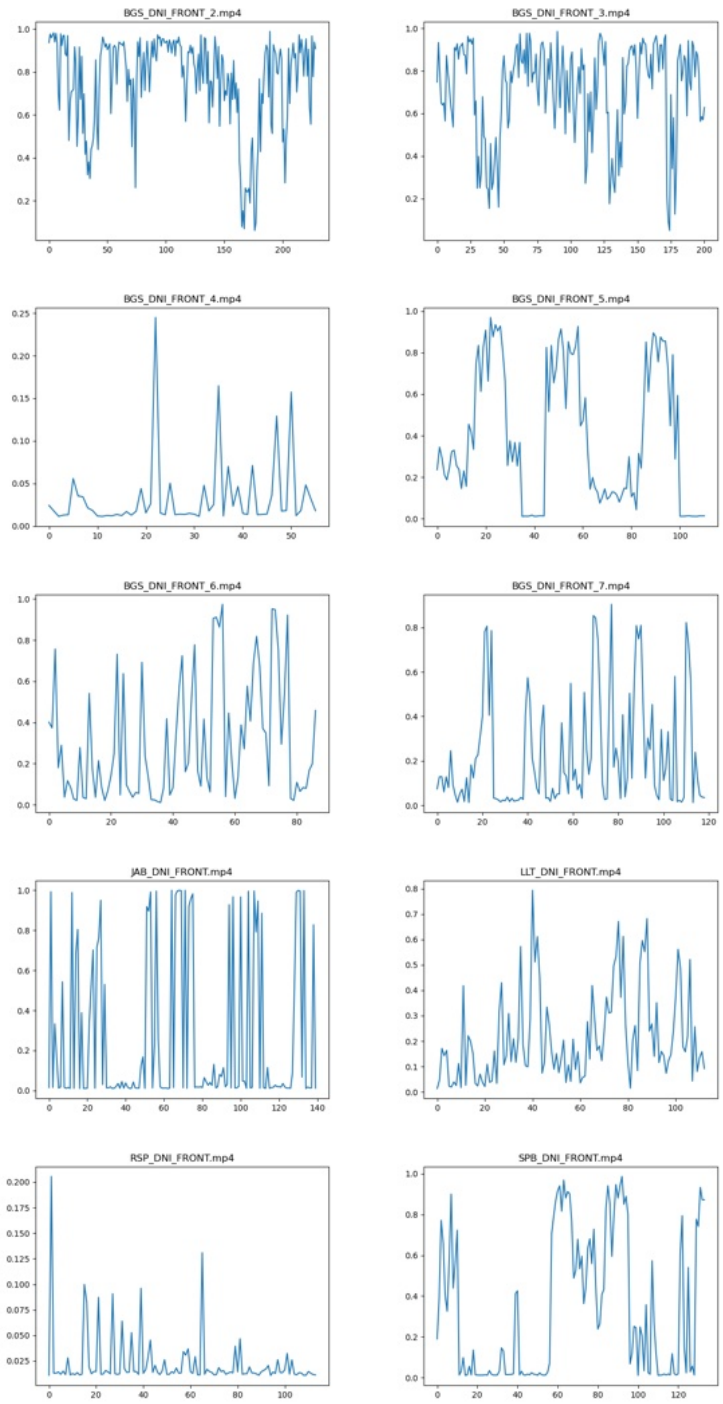

Figura 5.2: Gráficos de precisión de detección de DNI

En la mayoría detecta kinegrama a ratos, como se puede ver en las oscilaciones del valor de certeza. Esto se debe a que en ciertas partes del vídeo, el kinegrama es visible y en otras no, dado que está diseñado para que se muestre de manera distinta

según el ángulo de incidencia (véase anexo A: Características del DNI). Ello parece indicar que el algoritmo funciona correctamente, dado que solo se debería detectar en algunos fotogramas, no en todos.

Sin embargo, en los ejemplos 2 y 5 de la columna de la izquierda no lo detecta, pues la certeza no pasa del 20 %. No se conoce con certeza el porqué, pero puede ser por las condiciones del vídeo.

5.2. Reconocimiento de texto

Para probar el correcto funcionamiento del algoritmo, se ha probado con 10 ejemplos de DNI 3.0 y comprobado si los datos leídos se corresponden con los datos verdaderos, siendo en este caso los datos de filiación (nombre, apellidos, etc.), fechas de nacimiento y validez, número de soporte, DNI y CAN (véase anexo A: Características del DNI). Dichos ejemplos son vídeos grabados de varios DNI 3.0 enseñando el documento y girándolo. El algoritmo debe entonces analizar el vídeo, segmentar los datos y leerlos correctamente.

En la tabla 5.1 se muestra, para cada dato y muestra, si se ha leído el dato correctamente; siendo las filas cada uno de los ejemplos y las columnas los datos a leer. La tabla 5.2 indica en qué fracción de fotogramas se ha predicho correctamente, es decir, un valor de 0,9 indica que en el 90 %.

En total se han detectado correctamente 77 de los 100 campos en total, el 77 %.

	apellido1	apellido2	nombre	sexo	nacionalidad	fecha de nacimiento	num soport	validez	dni	can
0	X	X	X	X	X	X		X	X	X
1	X	X	X	X	X			X	X	X
2										X
3	X	X	X	X	X	X	X	X	X	X
4	X	X	X	X	X	X	X	X	X	X
5	X	X	X	X	X	X	X	X	X	X
6				X	X			X	X	X
7	X	X	X	X	X			X	X	X
8		X	X	X	X	X			X	X
9		X	X		X	X		X	X	X

Tabla 5.1: Resultados de si se ha leído el dato correctamente

	apellido1	apellido2	nombre	sexo	nacionalidad	fecha de nacimiento	num soport	validez	dni	can
0	0,9694	0,8996	0,6769	0,6245	0,9039	0,0262	0,0044	0,8035	0,9039	0,9956
1	0,8177	0,7931	0,4089	0,5271	0,6207	0,0148	0,0049	0,6798	0,7241	0,9212
2	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0411
3	0,9189	0,9369	0,7568	0,7117	0,8378	0,1712	0,0721	0,7117	0,8468	1,0000
4	0,8391	0,9080	0,6322	0,7471	0,7241	0,1609	0,0805	0,6207	0,8506	0,9425
5	0,7479	0,9244	0,4454	0,7227	0,5882	0,1008	0,0756	0,5966	0,6218	0,8992
6	0,0214	0,0071	0,0000	0,0143	0,0786	0,0000	0,0000	0,0357	0,2429	0,1929
7	0,2566	0,1593	0,0885	0,0177	0,1504	0,0000	0,0000	0,0088	0,1150	0,4248
8	0,4211	0,4123	0,3860	0,0351	0,3860	0,1491	0,0263	0,0000	0,3860	0,4211
9	0,5652	0,6304	0,2681	0,0000	0,6449	0,0870	0,0000	0,5652	0,4130	0,6739

Tabla 5.2: Frecuencias relativas con las que se han leído los resultados correctos

Dados los resultados, el OCR tiene una precisión mejorable. Algunos campos tiene dificultad para leerlos, como el número de soporte que solo se detecta bien en tres ejemplos, y depende mucho de las condiciones de la imagen, como en el ejemplo 2 que solo detecta el CAN. En otros, como el CAN o el DNI, se detectan en la mayoría.

Es necesario revisar el proceso de preprocesado para mejorar la precisión con la que el OCR detecta los campos. Muchas veces la detección falla por un par de caracteres y puede que el modelo necesite visualizar mejor el texto.

Sería interesante entrenar el modelo de Tesseract-OCR con la fuente específica de los DNI, dado que las pruebas se han realizado con el modelo predeterminado. Ello podría proporcionar una mejora de la precisión.

5.3. Identificación de tipo de DNI

Se ha realizado el experimento utilizando 2 clases (anversos de DNI 3.0 y 4.0) y se ha repetido con las 4 clases (DNI 3.0 y 4.0 por el anverso y el reverso) y una partición de 70/20/10 para los conjuntos de entrenamiento, pruebas y valdiación respectivamente para ambos. Los resultados son los siguientes (tabla 5.3):

Experimento	Accuracy	Precision	Recall	F1	Pérdida
2 clases	1.0000	1.0000	1.0000	1.0000	0.0000
4 clases	1.0000	1.0000	1.0000	1.0000	0.0000

Tabla 5.3: Resultados del entrenamiento de clasificador de DNI

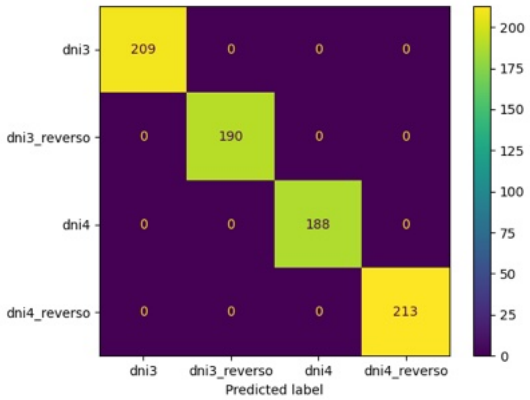

Figura 5.3: Matriz de confusión del detector del tipo de DNI

El modelo obtiene unos resultados expecionales. Cabe destacar que puede no ser lo suficientemente robusto: se han realizado cambios de saturación, luminosidad, nitidez y ruido, pero no se ha probado con un conjunto de datos reales (principalmente por falta de datos).

5.4. Detección de moiré

Se han entrenado varios hipermodelos para determinar cuál algoritmo es el más eficaz distinguiendo las imágenes con moiré y, para cada algoritmo, los hiperparámetros más adecuados; utilizando búsqueda en cuadrícula y utilizando validación cruzada de 5 particiones. Los resultados obtenidos son los que se muestran en la tabla 5.4:

Algoritmo	Accuracy	Precision	Recall	F1	Hiperparámetros
Random Forest	0.9638	1.0	0.9210	0.9589	'max_depth': 10 'n_estimators': 75
SVM	0.7108	0.6206	0.9473	0.75	'C': 0.0001 'kernel': 'linear'
KNN	0.6385	0.5833	0.7368	0.6511	'n_neighbors': 11 'weights': 'distance'

Tabla 5.4: Resultados del entrenamiento para detección de moiré

Como se puede observar, el mejor algoritmo para la tarea es el Random Forest. En concreto, uno con 75 estimadores y una profundidad máxima de 10. El modelo obtiene una puntación F1 del 95,89 %, un resultado aceptable.

Los otros algoritmos, SVM y KNN, obtienen puntuaciones del 75 % y 65,11 % respectivamente, lo que indica que no son especialmente adecuados para esta cuestión. Interesantemente, obtienen mucho mejor *recall* que *precision*, lo que indica que son más dados a detectar falsos positivos que falsos negativos, al contrario que el Random Forest, que detecta más falsos negativos.

En cuando al KBest, las características elegidas son las siguientes, de la librería sewar [12]:

- *Universal Quality Image Index (UQI)*
- *Erreur Relative Globale Adimensionnelle de Synthèse (ERGAS)*
- *Spatial Correlation Coefficient (SCC)*
- *Relative Average Spectral Error (RASE)*
- *Visual Information Fidelity (VIF)*

Las figuras 5.4 y 5.5 presentan ejemplos de detección de moiré con imágenes antes y después de los filtros y la predicción («clean» o «moiré»).

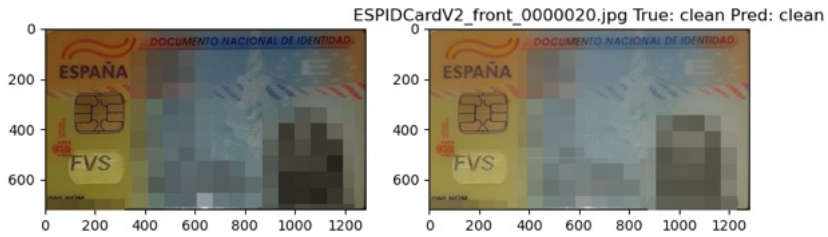

Figura 5.4: Ejemplo de detección de imagen limpia

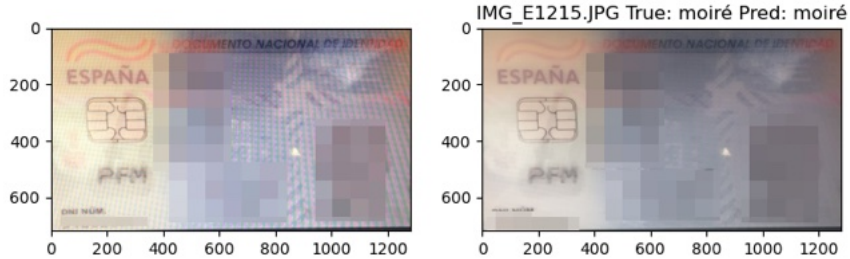

Figura 5.5: Ejemplo de detección de imagen con moiré

5.5. Estimación de calidad de imágenes de personas

En la figura 5.6 se muestran algunas imágenes de los conjuntos de datos utilizados y sus puntuaciones obtenidas en una escala del 0 al 100:

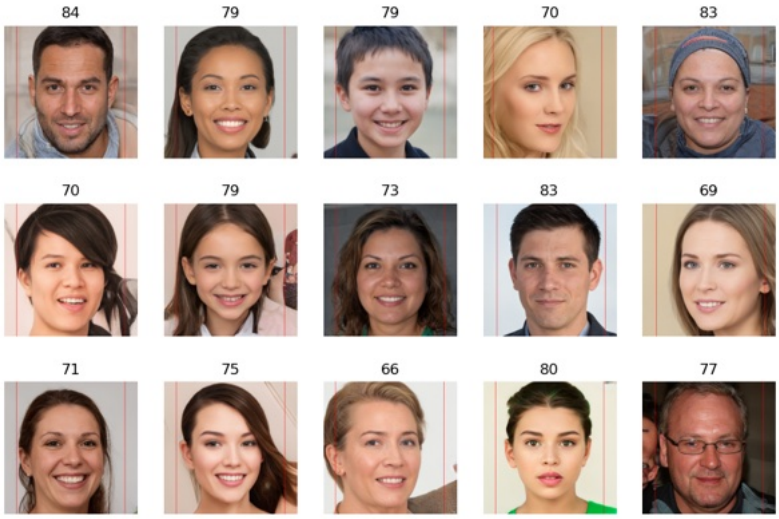

Figura 5.6: Ejemplos de estimaciones de imágenes

Las líneas rojas muestran los puntos de corte de las imágenes para ajustarlas a las dimensiones del formato carnet (26:32, véase anexo B: Estándares de fotografías para carnet).

Las puntuaciones difieren ligeramente en los ejemplos: por ejemplo, la cuarta imagen de la primera fila y la última imagen de la segunda fila tienen menores puntaciones al tener la cabeza girada. La sonrisa resta puntos en la mayoría de las imágenes como en las tres primeras de la última fila, ya que se requiere una expresión neutra.

5.6. Gafas

El modelo se ha ejecutado durante diez épocas utilizando el optimizador Adam y una partición de 70/20/10 para los conjuntos de entrenamiento, pruebas y valdiación respectivamente. Al final del entrenamiento, obtiene las métricas de la tabla 5.5:

Accuracy	Precision	Recall	F1	Pérdida
0.9688	0.975	0.9172	0.9428	0.1450

Tabla 5.5: Resultados del detector de gafas

Y la matriz de confusión obtenida es la siguiente:

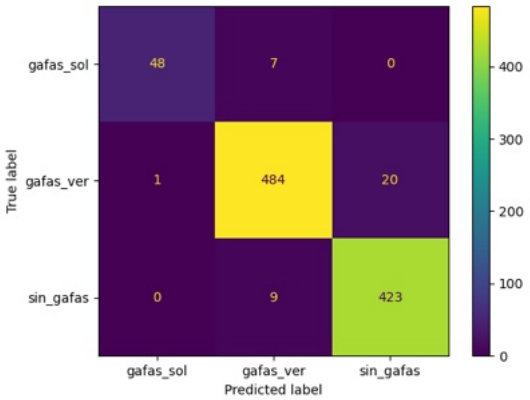

Figura 5.7: Matriz de confusión de identificación de gafas

Figura 5.8: Ejemplo de predicción

Se puede concluir que el modelo tiene un rendimiento bueno. A diferencia de otros modelos, este distingue entre gafas de ver (transparentes) y gafas de sol (con cristales oscuros).

Algunas de las malas detecciones pueden deberse a imágenes ambiguas. Por ejemplo, algunas imágenes están defectuosas y presentan gafas mal generadas, como en la figura 5.9:

Figura 5.9: ¿Lleva o no gafas?

5.7. Generación de DNI sintéticos

A continuación, se presentan algunos ejemplos de DNI generados de varios tipos, como se muestran en las figuras siguientes.

Las figuras 5.10 y 5.11 comparan anversos de DNI 3.0 sintéticos con uno real, las figuras 5.12 y 5.13 comparan anversos de DNI 4.0 sintéticos con uno real, las figuras 5.14 y 5.15 comparan reversos de DNI 3.0 sintéticos con uno real y las figuras 5.16 y 5.17 comparan reversos de DNI 4.0 sintñeticos con uno real.

La tabla 5.6 indica la calidad de las fotos utilizadas en los DNI, calculada en el apartado 4.5.

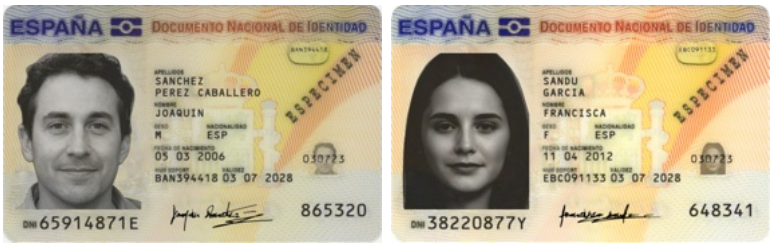

Figura 5.10: DNI 3.0 sintéticos

Figura 5.11: DNI 3.0 real

Figura 5.12: DNI 4.0 sintéticos

Figura 5.13: DNI 4.0 real

DNI	Calidad de la imagen
DNI 3.0 (1)	91
DNI 3.0 (2)	91
DNI 4.0 (1)	94
DNI 4.0 (2)	91

Tabla 5.6: Puntuaciones de las imágenes usadas en los DNI

Figura 5.14: DNI 3.0 reverso sintéticos

Figura 5.15: DNI 3.0 reverso real

Figura 5.16: DNI 4.0 reverso

Figura 5.17: DNI 4.0 reverso real

Sería interesante comprobar si un modelo es capaz de discernir dichos DNI sintéticos de DNI reales, con el fin de tener un mejor entendimiento de cuán realistas son las falsificaciones realizadas.

Faltaría, además, añadir imitaciones de las medidas de seguridad como el kinegrama o el embozado (véase anexo A: Características del DNI), o renderizar vídeos con ellos donde se muevan y cambien dinámicamente.

Capítulo 6

Conclusiones y trabajos futuros

En este trabajo, se ha realizado un estudio sobre los diferentes puntos que componen un documento de identidad y que verifican su veracidad. Se ha trabajado en métodos para identificar algunas de estas medidas de seguridad y así discernir los documentos de identidad auténticos de las falsificaciones.

Asimismo, se ha estudiado cómo posibles atacantes podrían generar falsificaciones con el fin de burlar las medidas de seguridad de los propios DNI y de los algoritmos de seguridad, para conocer más sobre los documentos de identidad y sus métodos de falsificación, así como de cómo se podrían detectar.

Aparte de esto, se ha permitido disponer de un conjunto de datos de documentos de identidad sintéticos, para su uso con fines de investigación, ya que, al ser información sensible y personal, es difícil disponer de conjuntos de datos de DNI.

Como trabajos futuros, se proponen los siguientes puntos:

- Extender el trabajo a otros tipos de documentos, como pasaportes, tarjetas de extranjería o permisos de conducción.
- Profundizar en el desarrollo del OCR, probando diferentes métodos y optimizando el modelo para las fuentes concretas de los documentos de identidad.
- Ampliar el análisis de calidad de imágenes.

Anexos

Anexo A

Características del DNI

El DNI (Documento Nacional de Identidad) es un documento emitido por la Dirección General de la Policía con el fin de acreditar la identidad y los datos personales de su titular [23][24]. Es obligatorio desde los 14 años e identifica a cada persona por un número único de 8 dígitos, más una letra que es el resultado del módulo del número (como se indica en la tabla A.1).

Resto	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22
Letra	T	R	W	A	G	M	Y	F	P	D	X	B	N	J	Z	S	Q	V	H	L	C	K	E

Tabla A.1: Letra del DNI

Además, a partir de 2006, el DNI incorpora un chip donde se incluyen un par de certificados de clave pública con los datos del usuario, para autenticarse en servicios del gobierno o firmar documentos.

A.1. DNI Franquista

El DNI surgió como una tentativa del general Franco para identificar y controlar a la población, sustituyendo a las cartas de seguridad y pasaportes interiores de la Policía y a las cédulas municipales. En 1946 se publicó un concurso por el que los ciudadanos podían presentar sus bocetos por un premio de 30 000 pesetas.

Los primeros DNI se empezaron a expedir en 1951. Los primeros números estaban

reservados, correspondiendo el 1 al *tío Paco*, el 2 a su mujer, el 3 a su hija; y del 10 al 99 a la familia real, excepto el 13, que se omitió por superstición.

Constaba de una tarjeta de cartulina y tuvo 5 versiones en las que cambiaban ligeramente el diseño y la distribución de datos personales, más una edición para la población saharaui.

Figura A.1: DNI franquista

Fuente: [23]

A.2. Primer DNI informatizado

Esta versión del DNI se empezó a expedir en 1990. Estaba formado por una cartulina plastificada y tenía un diseño mucho más similar a los DNI actuales. Tuvo 3 ediciones con pequeñas modificaciones.

Figura A.2: DNI 1.0

Fuente: [23]

A.3. DNIe

Primer DNI electrónico introducido en 2006, está fabricado de policarbonato, con las dimensiones de las tarjetas de crédito comúnmente utilizadas (85,60 mm de ancho X 53,98 mm de alto). Incorpora un chip que permite el uso de certificados de clave privada para su uso en servicios electrónicos, mediante el uso de hardware específico.

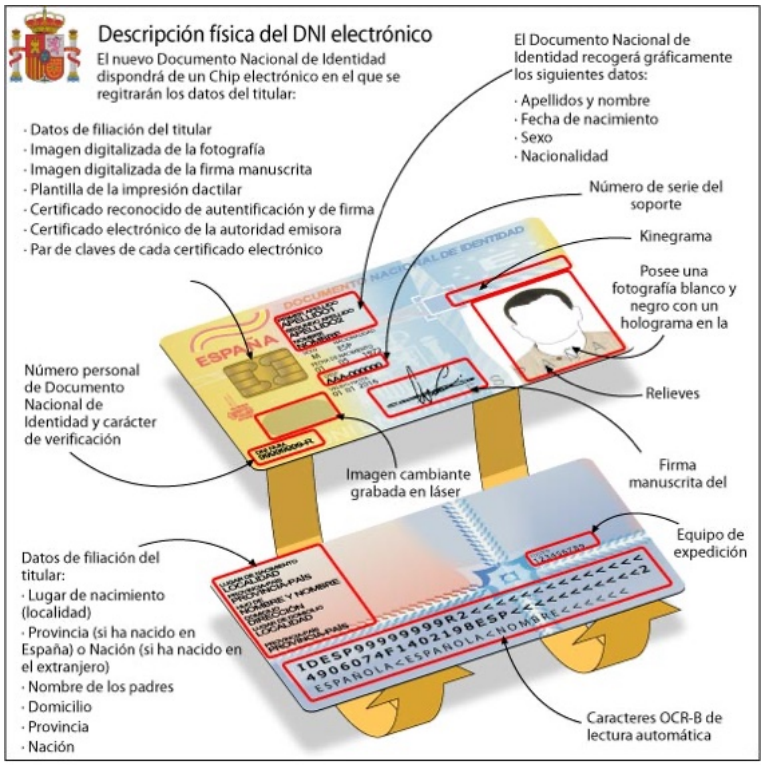

Figura A.3: Medidas de seguridad del DNIe

Fuente: Cuerpo Nacional de Policía - dnielectronico.com

A.4. DNI 3.0

El DNI 3.0 es la revisión del DNI electrónico introducida en diciembre de 2015. Al igual que las versiones anteriores, está fabricado de policarbonato, con las dimensiones de una tarjeta de crédito. Su principal novedad es la incorporación de un chip NFC para la utilización de los certificados electrónicos sin la necesidad de un lector externo. [25]

Los datos que incluye el DNI 3.0 son los siguientes:

- Anverso:
  - Número de DNI.
  - Datos de filiación: nombre y apellidos, fecha de nacimiento y nacionalidad.

- Número de soporte: 3 letras y 6 dígitos aleatorios.
- Fecha de validez.
- CAN: código de seguridad para el uso del DNI a través de protocolos seguros de comunicación.
- Fotografía.
- Firma.

- Reverso:
  - Más datos de filiación: dirección, población y provincia de nacimiento y nombres de los progenitores.
  - Código del equipo expedidor.
  - Caracteres MRZ: secuencia de caracteres en formato estándar pensado para ser leído mediante OCR.

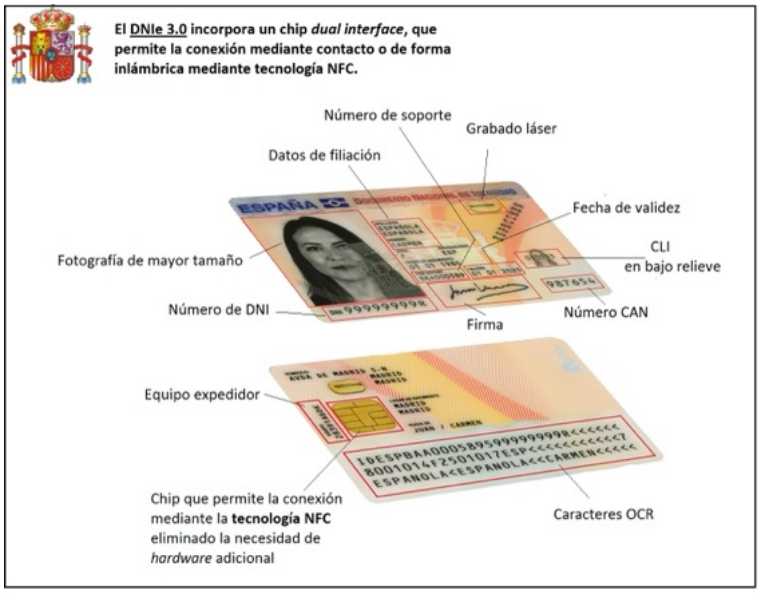

Figura A.4: Campos del DNI 3.0

Fuente: Cuerpo Nacional de Policía - dnielectronico.com

Además, incluye una serie de elementos físicos de seguridad, como se muestra en

la figura A.5:

- Anverso:
  - Kinegrama: impresión de difracción microscópica. Al mover la fuente de luz con respecto al DNI (incluyendo girar el propio DNI), permite visualizar el escudo con diferentes coloraciones y animaciones.
  - Tinta ópticamente variable: Tinta que contiene en su estructura finas partículas que otorgan el efecto óptico de variabilidad del color cuando se cambia el ángulo de incidencia de la luz y de observación.
  - Ventana transparente con grabado láser: incluye el número de soporte.
  - Changeable Laser Image (CLI) en bajo relieve: es una versión holográfica pequeña de la foto de la persona grabada con láser. Encima de ella se incluye la fecha de expedición en formato «ddmmaa».
  - Embozado efecto mate: dos franjas oblicuas con impresión ligeramente distinta.
  - Embozado en alto relieve: formas geométricas impresas en relieve en el documento.
  - Tintas UV en iris: Tintas solo visibles mediante luz ultravioleta.
- Reverso:
  - Tinta Oasis: tinta opaca que oculta las capas de debajo. Al verla a través de un filtro polarizado, deja ver dichas capas, revelando el patrón de seguridad.
  - Ventana transparente con grabado láser.
  - Tintas UV en iris

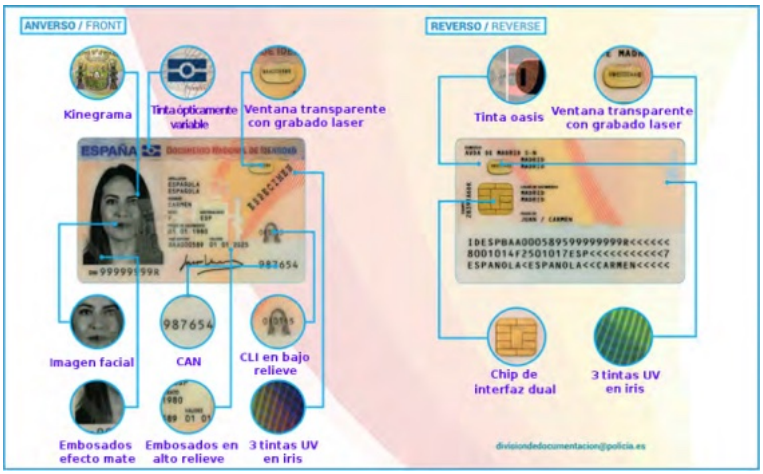

Figura A.5: Medidas de seguridad del DNI 3.0

Fuente: Cuerpo Nacional de Policía - dnielectronico.com

A.5. DNI 4.0

El DNIe 4.0 nace a raíz Reglamento UE 2019/1157 del Parlamento Europeo y del Consejo de 20 de junio de 2019 sobre el refuerzo de la seguridad de los documentos de identidad de los ciudadanos de la Unión y a los miembros de sus familias que ejerzan su derecho a la libre circulación. Tuvo su presentación el día 2 de junio de 2021 para adaptarse al nuevo formato europeo.

Incluye estos elementos físicos de seguridad:

- Anverso:
    - Kinegrama: impresión de difracción microscópica. Al mover la fuente de luz con respecto al DNI (incluyendo girar el propio DNI), permite visualizar el escudo con diferentes coloraciones y animaciones.
    - Tinta ópticamente variable: Tinta que contiene en su estructura finas partículas que otorgan el efecto óptico de variabilidad del color cuando se cambia el ángulo de incidencia de la luz y de observación.
    - Ventana transparente con grabado láser: incluye el número de soporte.
    - Changeable Laser Image (CLI) en bajo relieve: es una versión holográfica

pequeña de la foto de la persona grabada con láser. Encima de ella se incluye la fecha de expedición en formato «ddmmaa».

- Fondos offset de seguridad: da forma al fondo de la imagen.
- Embozado en alto relieve: formas geométricas impresas en relieve en el documento.
- Tintas UV en iris: Tintas solo visibles mediante luz ultravioleta.

- Reverso:
  - Tinta Oasis: tinta opaca que oculta las capas de debajo. Al verla a través de un filtro polarizado, deja ver dichas capas, revelando el patrón de seguridad.
  - Microtexto: secuencias de caracteres impresos a muy bajo tamaño, lo que los hace muy difíciles de fotocopiar
  - Ventana transparente con grabado láser.
  - Tintas UV en iris.

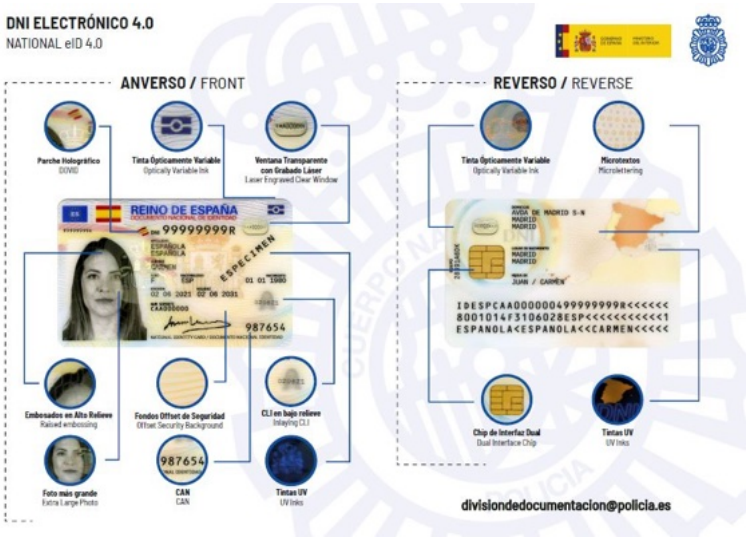

Figura A.6: Medidas de seguridad del DNI 4.0

Fuente: Cuerpo Nacional de Policía - dnielectronico.com

Anexo B

Estándares de fotografías para carnet

Las imágenes utilizadas en documentos oficiales deben cumplir una serie de estándares de calidad con el fin de que la persona que identifica sea reconocible tanto por personas como por máquinas. Ello incluye que el rostro estré centrado y sea visible, que la imagen tenga una resolución, brillo y contraste adecuados, etc.

El estándar NIST FRVT define una serie de métricas para evaluar la calidad de la imagen [26]:

- Número de caras: solo debe aparecer una cara visible en la foto.
- Rotación: la cabeza de la persona debe estar centrada, es decir, la rotación debe ser la mínima posible. La rotación se mide en tres componentes (llamados alabeo, cabeceo y guiñada), cada una siendo la rotación a través de un eje. Ejemplos en las figuras B.1.

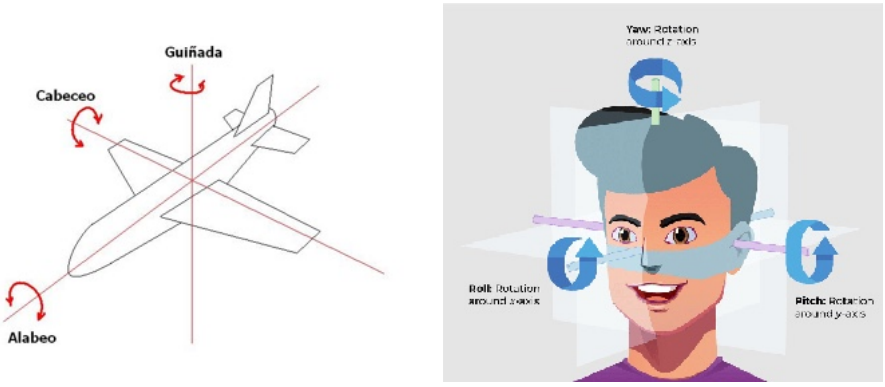

Figura B.1: Ejes de rotación de la cabeza

Fuente: Quirón5, CC BY-SA 3.0, via Wikimedia Commons

Fuente: [27]

- Apertura de los ojos: la persona debe tener los ajos abiertos.
- Gafas: está permitido utilizar gafas transparentes pero no gafas de sol.
- Boca abierta: cuanto más cerrada esté la boca, mejor.
- Oclusión facial: la cara debe estar al descubierto, sin que el pelo o mascarillas tapen parte de esta.
- Distancia de los ojos a los bordes: la cara debe estar centrada y no debe estar cortada por los bordes. Medir la distancia de los ojos a cada uno de los bordes de la imagen permite determinar dichas condiciones con relativa exactitud.
- Distancia entre los ojos: permite estimar la resolución de la imagen y el espacio que ocupa la cara en la imagen.
- Resolución: la imagen debe mostrar el rostro con un nivel de detalle suficiente (cuanto más, mejor). Depende no sólo del tamaño de la imagen, sino de su nitidez.
- Fondo: cuanto más liso, uniforme y contraste más con la cabeza, más fácil es distinguir la cabeza del fondo, así como recortar el fondo.
- Exposición: es la cantidad de luz que capta el sensor de imagen de una cámara.

Si es correcta, la imagen tendrá un equilibrio entre luces y sombras y los detalles se apreciarán bien. En caso contrario, la imagen aparecerá demasiado clara o demasiado oscura y se perderá un buen nivel de detalle.

Figura B.2: Exposición de una imagen

Fuente: https://www.dzoom.org.es/

- Ruido: perturbaciones en la imagen. Puede ser de diversos tipos: patrones de moiré, ruido gaussiano, artefactos de compresión, etc.

  Específicamente para los documentos españoles (DNI, etc.), el Ministerio de Interior estipula que la imagen sea reciente, de 32 mm de alto por 26 mm de ancho; de fondo blanco, uniforme y liso; y que muestre completamente el óvalo de la cara, es decir, «tomada de frente con la cabeza totalmente descubierta y sin gafas de cristales oscuros o cualquier otra prenda que pueda impedir o dificultar la identificación de la persona» [28], así como correctamente iluminada y sin ruido. La imagen será de alta resolución a todo color e impresa en papel fotográfico de alta calidad.

Bibliografía

1. PRESS, Europa. *España es el país de la Unión Europea con más víctimas de robo de identidad en el último año, según el Eurostat* [online]. Europa Press, 2018-01-02 [visitado 2023-06-23]. Disp. desde: https://www.europapress.es/portaltic/ciberseguridad/noticia-espana-pais-union-europea-mas-victimas-robo-identidad-ultimo-ano-eurostat-20180102092136.html.
2. THONGKOR, Kharittha y AMORNRAKSA, Thumrongrat. Digital Image Watermarking for Photo Authentication in Thai National ID Card. En: *2012 9th International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology* [online]. Phetchaburi, Thailand: IEEE, 2012, págs. 1-4 [visitado 2023-03-20]. ISBN 978-1-4673-2025-2 978-1-4673-2026-9 978-1-4673-2024-5. Disp. desde DOI: 10.1109/ECTICon.2012.6254245.
3. MUDGALGUNDURAO, Raghavendra; SCHUCH, Patrick; RAJA, Kiran; RAMACHANDRA, Raghavendra; DAMER, Naser. Pixel-Wise Supervision for Presentation Attack Detection on Identity Document Cards. *IET Biometrics* [online]. 2022, vol. 11, no. 5, págs. 383–395 [visitado 2023-03-08]. ISSN 2047-4946. Disp. desde DOI: 10.1049/bme2.12088.
4. YU, Xin; DAI, Peng; LI, Wenbo; MA, Lan; SHEN, Jiajun; LI, Jia; QI, Xiaojuan. *Towards Efficient and Scale-Robust Ultra-High-Definition Image Demoireing* [online]. 2022-07-20. [visitado 2023-03-09]. Disp. desde arXiv: 2207.09935 [cs].
5. BENALCAZAR, Daniel; TAPIA, Juan E.; GONZALEZ, Sebastian y BUSCH, Christoph. Synthetic ID Card Image Generation for Improving Presentation Attack Detection. *IEEE Transactions on Information Forensics and Security*.

2023, vol. 18, págs. 1814-1824. ISSN 1556-6021. Disp. desde DOI: 10.1109/TIFS.2023.3255585.

6. NAJAFZADEH, Nima; KASHIANI, Hossein; EBRAHIMI SAADABADI, Mohammad Saeed; TALEMI, Niloufar Alipour; MALAKSHAN, Sahar Rahimi y NASRABADI, Nasser M. Face Image Quality Vector Assessment for Biometrics Applications. En: *2023 IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*. 2023, págs. 511-520. ISSN 2690-621X. Disp. desde DOI: 10.1109/WACVW58289.2023.00057.

7. ZENG, Wei; HUANG, Junjian; WEN, Shiping; FU, Zhenjiang. A Masked-Face Detection Algorithm Based on M-EIOU Loss and Improved ConvNeXt. *Expert Systems with Applications* [online]. 2023, vol. 225, pág. 120037 [visitado 2023-06-08]. ISSN 0957-4174. Disp. desde DOI: 10.1016/j.eswa.2023.120037.

8. CARRILLO FUERTES, Tomas Ivan. Desarrollo de un aplicativo movil para la extracción automática de información del documento de indentificación mediante visión computacional [online]. 2020 [visitado 2023-06-16]. Disp. desde: https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/16608.

9. *Face Dataset Of People That Don't Exist* [online]. [visitado 2023-06-01]. Disp. desde: https://www.kaggle.com/datasets/bwandowando/all-these-people-dont-exist.

10. *100k-Faces/Docs/0 at Master · Ozgrozer/100k-Faces* [online]. GitHub. [visitado 2023-06-12]. Disp. desde: https://github.com/ozgrozer/100k-faces.

11. *Glasses or No Glasses* [online]. [visitado 2023-06-01]. Disp. desde: https://www.kaggle.com/datasets/jeffheaton/glasses-or-no-glasses.

12. KHALEL, Andrew. *Sewar* [online]. 2023. [visitado 2023-06-12]. Disp. desde: https://github.com/andrewekhalel/sewar.

13. *INEbase / Demografía y población /Padrón /Apellidos y nombres más frecuentes / Últimos datos* [online]. INE. [visitado 2023-06-01]. Disp. desde: https://www.ine.es/dyngs/INEbase/es/operacion.htm?c=Estadistica_C&cid=1254736177009&menu=ultiDatos&idp=1254734710990.

14. ISO 3166-1. En: *Wikipedia, la enciclopedia libre* [online]. 2023 [visitado 2023-06-20]. Disp. desde: https://es.wikipedia.org/w/index.php?title=ISO_3166-1&oldid=150308566.

15. SAWANT, Mahesh. *Gender-and-Age-Detection* [online]. 2023. [visitado 2023-06-06]. Disp. desde: https://github.com/smahesh29/Gender-and-Age-Detection.

16. *INEbase/ Clasificaciones / Relación de Municipios, Provincias, Comunidades Autónomas y Sus Códigos 01-01-2011* [online]. [visitado 2023-06-09]. Disp. desde: https://www.ine.es/daco/daco42/codmun/codmun11/11codmunmapa.htm.

17. *CSV Con Las Provincias de España, Sus Respectivos Códigos y Prefijos | CSV with Spain Provinces, and Their Respectives Codes and Prefixes* [online]. Gist. [visitado 2023-06-01]. Disp. desde: https://gist.github.com/JustDevZero/139ad12e822c79496769.

18. *Callejero. Información adicional asociada. Códigos postales, zonas SER, categoría fiscal, parcela catastral, etc. - Conjunto de datos* [online]. [visitado 2023-06-09]. Disp. desde: http://datos.gob.es/es/catalogo/l01280796-callejero-informacion-adicional-asociada-codigos-postales-zonas-ser-categoria-fiscal-parcela-catastral-etc1.

19. ARG0S. *MRZ Generator & MRZ Checker* [online]. 2023. [visitado 2023-06-01]. Disp. desde: https://github.com/Arg0s1080/mrz.

20. OACI. Trazado De La Zona De Lectura Mecánica Del Mrotd De Tamaño Dv1 (Informativo). En: *Documentos de viaje de lectura mecánica* [online]. Octava edición/2021. Organización de Aviación Civil Internacional (OACI), [s.f.], pág. 33 [visitado 2023-06-01]. ISBN 978-92-9265-444-3. Disp. desde: https://www.icao.int/publications/Documents/9303_p5_cons_es.pdf.

21. 99DESIGNS. *OCR-B Sans Serif Font - Download Free Font* [online]. Download free fonts, 2020-07-23. [visitado 2023-06-01]. Disp. desde: https://befonts.com/ocr-b-sans-serif-font.html.

22. FONTS, 1001. *PWSignaturetwo Font · 1001 Fonts* [online]. 1001 Fonts. [visitado 2023-06-01]. Disp. desde: https://www.1001fonts.com/pwsignaturetwo-font.html.

23. *La evolución del DNI en España: cómo era y cómo es (FOTOS)* [online]. ElHuffPost, 2015-01-12. [visitado 2023-03-16]. Disp. desde: https://www.huffingtonpost.es/2015/01/12/evolucion-dni_n_6456474.html.

24. CAMPILLO, Rafael. *Tipos de DNI en España, evolución y significado de los campos del DNI 3.0* [online]. Mobbeel, 2019-03-12. [visitado 2023-04-18]. Disp. desde: https://www.mobbeel.com/blog/tipos-de-dni-evolucion-y-significado-de-los-campos-del-dni-3-0/.

25. *Descripción DNI 3.0* [online]. [visitado 2023-03-14]. Disp. desde: https://www.dnielectronico.es/PortalDNIe/PRF1_Cons02.action?pag=REF_103&id_menu=1.

26. *FRVT Quality Summarization and Analysis* [online]. [visitado 2023-06-01]. Disp. desde: https://pages.nist.gov/frvt/html/frvt_quality.html.

27. MEDEIROS, Paulo; SILVA, Gabriel; FERNANDES, Felipe; GENDRIZ, Ignacio; LINS, Hertz; BARROS, Daniele; NAGEM, Danilo y VALENTIM, Ricardo. Efficient Machine Learning Approach for Volunteer Eye-Blink Detection in Real-Time Using Webcam. *Expert Systems with Applications*. 2021, vol. 188, pág. 116073. Disp. desde DOI: 10.1016/j.eswa.2021.116073.

28. *Ministerio Del Interior | Documentación Necesaria Para Su Tramitación* [online]. [visitado 2023-06-27]. Disp. desde: https://www.interior.gob.es/opencms/es/servicios-al-ciudadano/tramites-y-gestiones/dni/documentacion-necesaria-para-su-tramitacion/.